Do Simbólico à Incerteza: inferindo a presença e a expansão de facções criminosas nos municípios da Amazônia Legal

Gabriel Menezes Rodrigues Luiz Felipe Gonzaga do Carmo

Joshua Tadeu Bastos Pereira Romário Roberto de Pádua Andrade

Ruan Pablo Nascimento de Aragão Fernando Teles dos Reis*

Novembro de 2026

Resumo

A presença de facções criminosas não aparece em nenhuma base oficial: é uma variável oculta. Combinamos as estatísticas de violência do Validador de Dados Estatísticos (VDE) do Sistema Nacional de Informações de Segurança Pública (SINESP), de 2020 a 2024, e a população do Instituto Brasileiro de Geografia e Estatística (IBGE) para inferi-la nos 808 municípios dos estados da Amazônia Legal, usando como referência o *Cartografias da Violência na Amazônia* de 2024. Percorremos as seis etapas do pipeline: árvore de decisão, modelos lineares, probabilidade, Naive Bayes com o algoritmo Esperança-Maximização (EM), rede bayesiana e lógica fuzzy. A rede bayesiana diagnóstica atinge área sob a curva ROC (AUC) de 0,81 (0,80 testando num estado que não viu). Sem usar nenhum dado de 2025, a probabilidade calculada antecipa quais municípios passaram a ter facção segundo a edição de 2025 (AUC 0,76): na prioridade fuzzy baixa, 14% entraram; na alta, 45%. A violência indica onde a facção tende a estar, mas não quando ela chega.

Palavras-chave: Facções criminosas. Amazônia Legal. Redes bayesianas. Lógica fuzzy. Aprendizado de máquina.

*Equipe 1 — P3 Segurança Pública. Trabalho da disciplina Fundamentos de Inteligência Artificial, Prof. Edjard Mota, Instituto de Computação (IComp), Universidade Federal do Amazonas (UFAM), 2026/2.

1 Introdução

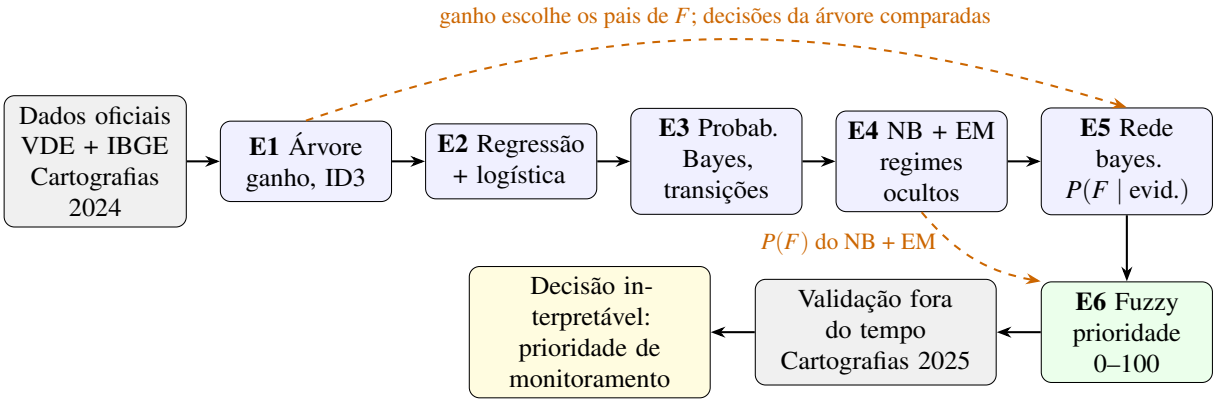
Nas duas últimas décadas, facções criminosas nascidas no Sudeste (Primeiro Comando da Capital, PCC, e Comando Vermelho) e grupos regionais se espalharam pela Amazônia, atraídos pelas rotas fluviais e terrestres da cocaína produzida na Bolívia, no Peru e na Colômbia (COUTO, 2020) e pelo sistema prisional, onde se organizam (SIQUEIRA; PAIVA, 2019). A literatura descreve uma interiorização das facções na região, ligada também ao garimpo ilegal (COUTO, 2024; CHAGAS, 2024). O *Cartografias da Violência na Amazônia*, do Fórum Brasileiro de Segurança Pública com o Instituto Mãe Crioula, mapeia município a município quais facções atuam na região: na 3ª edição (dados de 2024) havia registro em 259 dos 808 municípios dos nove estados; na 4ª edição (2025), em 344.

Esse mapeamento depende de trabalho de campo e de fontes policiais e não é atualizado continuamente. As estatísticas de violência, por outro lado, são publicadas todo ano pelo Ministério da Justiça. Trabalhos próximos usam aprendizado de máquina para prever homicídios em Belém a partir de boletins de ocorrência (RIBEIRO et al., 2021) e para prever a infiltração mafiosa em municípios italianos com validação fora do tempo (CAMPEDELLI; DANIELE; LE MOGLIE, 2024); neste último, os "falsos positivos" se parecem com municípios infiltrados ainda não detectados, ponto que retomamos na Seção 11. A pergunta deste trabalho é:

> O município da Amazônia Legal tem presença de facção criminosa (2024), dado o seu porte e o padrão de violência registrado entre 2021 e 2023? E o modelo antecipa quais municípios passaram a ter facção em 2025?

A resposta final é uma prioridade de monitoramento por município, produzida por um sistema fuzzy que recebe as probabilidades das Etapas 4 e 5 (Figura 1). A prioridade não é uma acusação: indica onde a inteligência policial teria mais chance de encontrar atuação de facção.

Figura 1 – Pipeline integrado



Nota: as setas tracejadas indicam reutilização: o ganho da Etapa 1 define os pais de `FACCAO` na rede, cujas decisões são comparadas às da árvore; a $P(F)$ do Naive Bayes + EM (Etapa 4) entra, com a da rede, na presença do sistema fuzzy.

Fonte: Elaborada pelos autores (2026).

2 Dados e protocolo de validação

Fontes. (i) Rótulos: Cartografias, 3ª edição (INSTITUTO MÃE CRIOULA; FÓRUM BRASILEIRO DE SEGURANÇA PÚBLICA, 2024) (Tabelas 13–21, presença em 2024) e 4ª edição (INSTITUTO MÃE CRIOULA; FÓRUM BRASILEIRO DE SEGURANÇA PÚBLICA, 2025) (quadros por estado, extraídos do PDF com `extrair_cartografias_2025.py`). (ii) Atributos: Validador de Dados Estatísticos (VDE) do Sistema Nacional de Informações de Segurança Pública (SINESP), mantido pelo Ministério da Justiça e Segurança Pública (MJSP) (MINISTÉRIO DA JUSTIÇA E SEGURANÇA PÚBLICA, 2024), 2020–2024, por município (homicídio doloso, tentativa, morte a esclarecer, latrocínio, mandados). (iii) População: Instituto Brasileiro de Geografia e Estatística (IBGE), Censo 2022 e estimativas (INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA, 2024), unida pelo código do município. Os 5.570 municípios do VDE casaram com o IBGE; os 808 dos 9 estados casaram com o Cartografias. (iv) Bases externas, usadas nos experimentos (Seção 9): autos de infração e termos de destruição do Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis (IBAMA) (INSTITUTO BRASILEIRO DO MEIO AMBIENTE E DOS RECURSOS NATURAIS RENOVÁVEIS, 2026), alertas do sistema de Detecção de Desmatamento em Tempo Real (DETER) do Instituto Nacional de Pesquisas Espaciais (INPE) (INSTITUTO NACIONAL DE PESQUISAS ESPACIAIS, 2026), faixa de fronteira, malha municipal e Regiões de Influência das Cidades (REGIC) do IBGE (INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA, 2024), todos de 2021–23 e agregados por município (`montar_bases_externas.py`). Dos arquivos do IBAMA, que identificam os autuados, guardamos só contagens por município.

Atributos. Para a árvore, o Naive Bayes e a rede, usamos atributos discretos e interpretáveis (Tabela 1). As taxas são médias anuais de 2021–23 por 100 mil habitantes (Censo 2022).

Tabela 1 – Atributos e alvo

Variável	Definição
`PORTE`	pequeno (<10 mil), médio (10–50 mil), grande (50 mil+)
`TXH`	taxa de homicídio 2021–23, em tercis
`TXT`	taxa de tentativas de homicídio 2021–23, em tercis
`ESC`	teve morte a esclarecer em 2021–23
`LATRO`	teve latrocínio em 2021–23
`UF/FRONT`	estado (unidade da federação) / estado faz fronteira com outro país
`ALVO`	facção registrada em 2024 (32,1%)

Fonte: Elaborada pelos autores com dados do SINESP/VDE, do IBGE e do *Cartografias da Violência na Amazônia* (2026).

Validação. Sempre com `seed = 42`: (a) validação cruzada estratificada de 5 dobras, recalculando os tercis de `TXH` e `TXT` com os cortes do treino de cada dobra, para o teste não influenciar a discretização; (b) *deixando um estado de fora* (treina com 8, testa no 9º); (c) *fora do tempo*: entre os 549 municípios sem facção em 2024, quais passaram a ter em 2025, rótulo que nenhum

modelo viu. Como as classes são desbalanceadas ("sempre não" acerta 67,9%), reportamos também a acurácia balanceada (média das taxas de acerto de cada classe) e a área sob a curva ROC (AUC, do inglês *Area Under the Receiver Operating Characteristic Curve*). A AUC é a probabilidade de o modelo atribuir um valor maior a um município com facção sorteado ao acaso do que a um sem facção: 0,5 equivale ao acaso e 1,0 a uma ordenação perfeita. Ela mede, portanto, se o modelo ordena bem os municípios, independentemente do limiar usado para decidir.

3 Etapa 1 — Árvore de decisão

Entropia e ganho (cálculo manual). Na raiz, 259 dos 808 municípios têm facção: $H = -\frac{259}{808}\log_2\frac{259}{808} - \frac{549}{808}\log_2\frac{549}{808} = 0{,}905$ bits. Para `PORTE`, os filhos são pequeno (27/267 com facção, $H = 0{,}473$), médio (145/435, $H = 0{,}918$) e grande (87/106, $H = 0{,}678$). A entropia ponderada é $(267 \cdot 0{,}473 + 435 \cdot 0{,}918 + 106 \cdot 0{,}678)/808 = 0{,}740$, e o ganho é $0{,}905 - 0{,}740 = 0{,}165$, o maior entre os seis atributos (Tabela 2).

Tabela 2 – Ganho de informação na raiz (nível 1)

	`PORTE`	`UF`	`LATRO`	`ESC`	`TXH`	`TXT`
Ganho	**0,165**	0,151	0,070	0,030	0,027	0,017

Fonte: Elaborada pelos autores (2026).

No **nível 2**, em todos os três ramos de porte o melhor atributo é `UF`: ganho de 0,167 entre os pequenos ($H = 0{,}473$), 0,133 entre os médios ($H = 0{,}918$) e 0,044 entre os grandes ($H = 0{,}678$). No **nível 3**, os atributos de violência finalmente aparecem: nos médios do Mato Grosso ($n = 61$, $H = 0{,}929$) o melhor é `TXT` (ganho 0,135); nos médios de Rondônia ($n = 23$, $H = 0{,}999$) e do Amazonas ($n = 48$, $H = 0{,}696$), `TXH` (0,164 e 0,107); nos médios do Maranhão ($n = 153$) e do Pará ($n = 90$), `LATRO` (0,040 e 0,035). A árvore diz, portanto, que o tamanho do município e o estado explicam a maior parte da presença de facção; a violência refina a decisão dentro de cada estado.

Implementação e validação. Implementamos o LEARN-DECISION-TREE (*Iterative Dichotomiser 3*, ID3) (RUSSELL; NORVIG, 2020) do zero e comparamos com o `DecisionTreeClassifier` (critério entropia) em 5 dobras (Tabela 3). As duas implementações sem poda dão o mesmo resultado (0,749 e 0,745). A poda por profundidade reduz o sobreajuste: o treino cai de 87% para 82% e o teste sobe para 78,6%. A Figura 2 mostra a curva de profundidade.

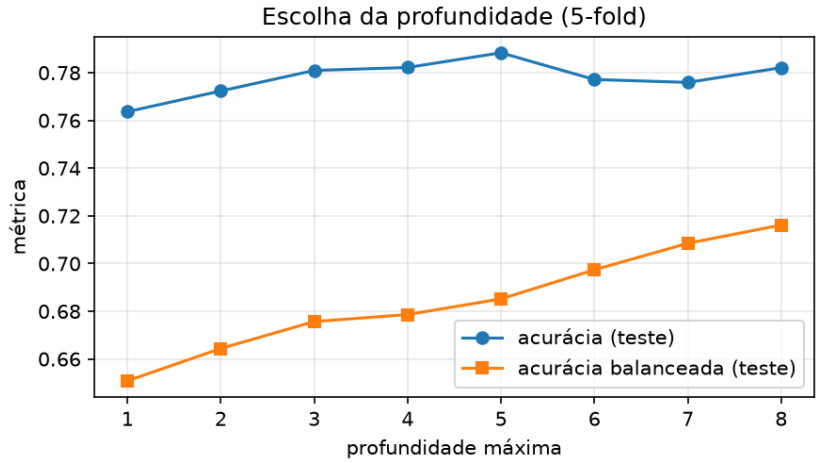
Monotonicidade. A regra mais simples sugerida pelos dados é $\forall x\,(\mathit{Pequeno}(x) \rightarrow \neg \mathit{Facção}(x))$. Ela cobre 267 municípios e acerta 89,9%. Mas, ao acrescentarmos um único fato novo, "o município fica no Acre" ou "em Roraima", a conclusão se inverte: todos os pequenos

Tabela 3 – Validação cruzada 5-fold (tercis calculados no treino de cada dobra)

Modelo	Treino	Teste	Bal.
ID3 própria, sem poda	0,874	0,749	0,687
ID3 própria, prof. 3	0,824	**0,786**	**0,708**
sklearn, sem poda	0,875	0,745	0,683
sklearn, prof. 4	0,799	0,782	0,679

Fonte: Elaborada pelos autores (2026).

Figura 2 – Acurácia de teste por profundidade máxima



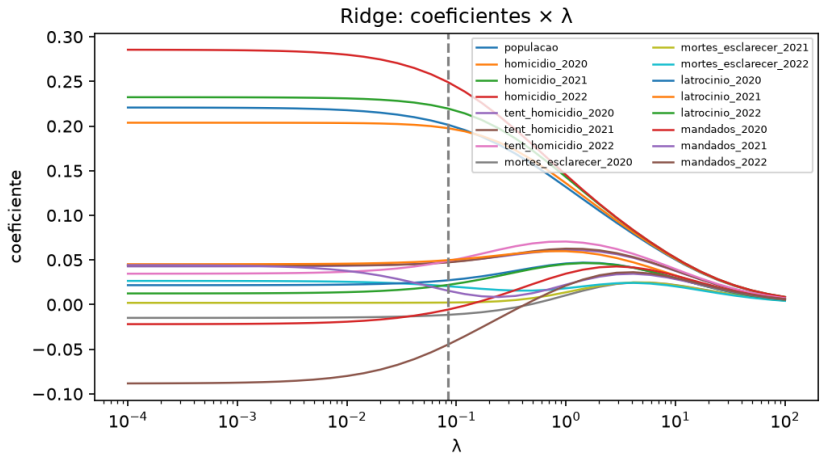
Fonte: Elaborada pelos autores (2026).

desses estados têm facção (3 de 3 e 2 de 2), e em Rondônia 9 de 22. São estados de fronteira, na rota da cocaína, onde a facção chega até às cidades pequenas. Na lógica clássica, o raciocínio é monotônico: se a regra foi aceita como axioma, nenhum fato novo a derruba, e a base passaria a ser inconsistente. No mundo real, a informação nova invalida a conclusão anterior. Esse é o limite das regras rígidas que motiva as etapas seguintes, em que as conclusões são graus de crença revisáveis.

4 Etapa 2 — Modelos lineares

Regressão. Como alvo contínuo usamos $y = \log(1 + \text{homicídios em 2023})$. Os 16 atributos são $\log(\text{população})$ e as contagens de 2020–2022 (em $\log(1+x)$). Divisão 80/20. A regressão univariada por fórmula fechada sobre os homicídios de 2022 dá $\hat{y} = 0{,}282 + 0{,}812\,x$ ($R^2 = 0{,}672$). A multivariada com gradiente descendente (GD) do zero (atributos padronizados, $\alpha = 0{,}05$, 5.000 iterações) chega a $R^2 = 0{,}763$. Como os 16 atributos são muito correlacionados (o mesmo evento em três anos seguidos), aplicamos Ridge: o λ escolhido por validação cruzada é 0,084, com $R^2 = 0{,}762$ (Figura 3). À medida que λ cresce, os coeficientes encolhem e deixam de oscilar entre anos correlacionados.

Figura 3 – Coeficientes do Ridge em função de λ



Fonte: Elaborada pelos autores (2026).

Logística. Para o problema da Etapa 1, implementamos a regressão logística (sigmoide + gradiente, com pesos de classe balanceados). Acurácia de 75,9% e balanceada de 0,737, idênticas ao `LogisticRegression`. Todos os modelos próprios coincidem com o scikit-learn até a terceira casa (Tabela 4).

Tabela 4 – Resultados no teste (20%); o scikit-learn dá os mesmos valores

Modelo	R^2	Acurácia (bal.)
Simples (hom. 2022 $\rightarrow$ 2023)	0,672	–
Multivariada (GD, 16 atributos)	0,763	–
Ridge ($\lambda = 0{,}084$)	0,762	–
Logística (facção)	–	0,759 (0,737)

Fonte: Elaborada pelos autores (2026).

5 Etapa 3 — Probabilidade

Cada município é tratado como um "mundo" possível, descrito por três variáveis binárias: F = tem facção em 2024; V = violência alta, isto é, taxa de homicídio de 2021–23 no tercil mais alto (acima de 28,6 por 100 mil habitantes ao ano); E = teve ao menos uma morte a esclarecer em 2021–23. A Tabela 5 dá a distribuição conjunta de F e V: cada célula é a fração dos 808 municípios com aquela combinação.

Bayes: do sentido causal ao diagnóstico. A facção provoca violência (disputas, execuções), então o sentido *causal* é $P(V \mid F)$: entre os municípios com facção, 44,0% têm violência alta. O analista faz o caminho inverso: observa a violência e quer saber se há uma facção por

Tabela 5 – Distribuição conjunta (4 eventos atômicos)

	$F=0$	$F=1$	$P(V)$
$V=0$	0,4876	0,1795	0,6671
$V=1$	0,1918	0,1411	0,3329
$P(F)$	0,6795	0,3205	1,0000

Fonte: Elaborada pelos autores com dados do SINESP/VDE, do IBGE e do *Cartografias da Violência na Amazônia* (2026).

trás, o sentido *diagnóstico*. A regra de Bayes inverte a condicional:

$$P(F \mid V) = \frac{P(V \mid F)\,P(F)}{P(V)} = \frac{0{,}440 \times 0{,}3205}{0{,}3329} = 0{,}424,$$

o mesmo valor da leitura direta da tabela ($0{,}1411/0{,}3329$). Sem violência alta, a proporção cai para $P(F \mid \neg V) = 0{,}1795/0{,}6671 = 0{,}269$. A violência alta multiplica a chance de facção por 1,6, mas não é prova: 58% dos municípios violentos não têm facção registrada.

Por que a lógica de primeira ordem (LPO) não diz "42% de chance". Uma regra lógica teria de escolher entre $\forall x\,(\mathit{ViolênciaAlta}(x) \rightarrow \mathit{Facção}(x))$ e $\forall x\,(\mathit{ViolênciaAlta}(x) \rightarrow \neg\mathit{Facção}(x))$. As duas são falsas: a primeira tem 155 contraexemplos (municípios violentos sem facção) e a segunda, 114. A LPO só atribui verdadeiro ou falso; para dizer "em 42% dos casos" é preciso uma medida de crença, que é a probabilidade.

Regra da cadeia. Com E, a conjunta das três variáveis pode ser montada passo a passo: $P(F,V,E) = P(F)\,P(V \mid F)\,P(E \mid F,V)$. Por exemplo, $P(F{=}1,V{=}1,E{=}1) = 0{,}3205 \times 0{,}440 \times 0{,}877 = 0{,}124$. As 8 combinações calculadas assim coincidem com a contagem direta e somam 1.

Independência condicional. O Naive Bayes da Etapa 4 supõe que, conhecida a classe, os sintomas são independentes: $P(V,E \mid F) = P(V \mid F)\,P(E \mid F)$. Testamos essa hipótese. Entre os municípios sem facção, $P(V,E \mid F{=}0) = 0{,}204$, contra o produto 0,167 ($\chi^2 = 14{,}5$, $p < 10^{-3}$); entre os com facção, 0,386 contra 0,350 ($p = 0{,}006$). Nos dois grupos, violência alta e morte a esclarecer aparecem juntas mais do que a independência permitiria: entre os com facção, a chance de morte a esclarecer é de 88% com violência alta e de 73% sem ela. A hipótese do Naive Bayes é violada, porque os dois sintomas compartilham uma causa que não está no modelo: o volume de violência.

Transições 2024 → 2025. A 4ª edição do Cartografias mostra a dinâmica (Tabela 6). A diagonal reúne os municípios que mantiveram o regime. Dos 549 sem registro em 2024, 129 (23,5%) passaram a ter facção em 2025, e a chance cresce com o porte: 13,8% nos pequenos, 30,7% nos médios e 36,8% nos grandes. Pela regra de Bayes,

$$P(\text{entrada} \mid \text{grande}) = \frac{P(\text{grande} \mid \text{entrada})\,P(\text{entrada})}{P(\text{grande})} = \frac{0{,}054 \times 0{,}235}{0{,}035} = 0{,}368,$$

em que 0,054 é a fração de grandes entre os 129 que entraram e 0,035, entre os 549 sem registro. No sentido oposto, 45 municípios "saíram" da lista (32 + 13): parte da mudança entre as edições vem da melhoria do método, como o próprio Cartografias reconhece.

Tabela 6 – Regimes de facção em 2024 e 2025 (municípios)

2024 \ 2025	sem reg.	uma	disputa	total
sem registro	420	111	18	549
uma facção	32	126	16	174
disputa	13	18	54	85

Fonte: Elaborada pelos autores com dados do *Cartografias da Violência na Amazônia*, 3ª e 4ª edições (2026).

6 Etapa 4 — MLE, MAP, Naive Bayes e EM

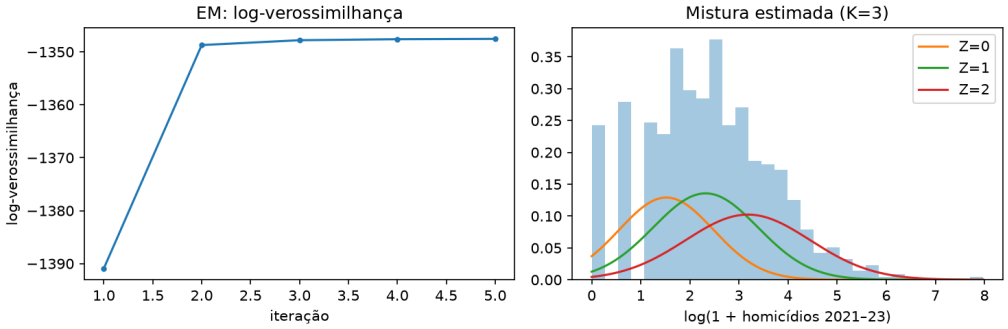
MLE e MAP. Para cada estado, estimamos $\theta = P(\text{facção})$ a partir de k municípios com facção entre n. A estimativa de máxima verossimilhança (MLE, do inglês *Maximum Likelihood Estimation*) é a proporção observada, $\hat{\theta}_{MLE} = k/n$. Com uma crença inicial (*prior*) Beta(2,2), simétrica em torno de 0,5, a estimativa de máximo *a posteriori* (MAP) é $\hat{\theta}_{MAP} = (k+1)/(n+2)$: é como somar aos dados um município fictício com facção e outro sem. Onde há poucos municípios, o MLE vai aos extremos: no Acre ($k = n = 22$), $\hat{\theta}_{MLE} = 1$, o que tornaria impossível um município acriano sem facção; o MAP dá $23/24 = 0{,}958$. Em Roraima, 0,933 contra 0,882. Nos estados grandes (PA, MA, MT), os dois coincidem até a segunda casa: o prior só pesa quando há pouca evidência.

Naive Bayes do zero. O Naive Bayes (NB) aplica a regra de Bayes aos seis atributos da Etapa 1 de uma vez, multiplicando as probabilidades condicionais de cada um sob a hipótese de independência dada a classe, que a Etapa 3 mostrou ser só aproximada. As probabilidades vêm de contagens com suavização de Laplace (soma 1 a cada contagem), a mesma ideia do prior Beta(2,2): sem ela, $P(\texttt{UF}{=}\text{AC} \mid \text{sem facção}) = 0$ anularia o produto para qualquer município do Acre. Em 5 dobras, a acurácia é de 77,2% e a balanceada, de 0,737 (de 0,668 a 0,789 entre as dobras), iguais às do `CategoricalNB` do scikit-learn.

EM com variável oculta. O Cartografias classifica cada município em "sem registro", "uma facção (domínio)" ou "disputa" (duas ou mais facções). Tratamos esse regime como uma variável oculta Z e perguntamos se ele pode ser recuperado só a partir dos homicídios, sem ver o rótulo. Modelamos $x = \log(1 + \text{homicídios 2021–23})$ como uma mistura de 3 gaussianas, uma por regime, ajustada pelo algoritmo Esperança-Maximização (EM, do inglês *Expectation-Maximization*; `em.py`). O passo E calcula a probabilidade de cada município pertencer a cada grupo; o passo M reestima, com essas probabilidades, o peso θ, a média e a variância de cada gaussiana.

O rótulo só entra depois, para conferir os grupos (Tabela 7). No grupo menos violento, 88,7% estão sem registro e 1,7% em disputa; no mais violento, dois terços têm facção e 28,8% estão em disputa, quase o triplo da média da região (10,5%). A violência carrega a assinatura da disputa entre facções; o domínio de uma facção só, nem sempre ("paz do domínio"). A log-verossimilhança cresce a cada iteração e atinge o critério de parada (variação relativa menor que 10^{-4}) em 5 iterações (Figura 4). Com 10^{-6}, o EM leva 358 iterações e a log-verossimilhança sobe de $-1347{,}5$ para $-1327{,}6$: o grupo menos violento passa a reunir só os 52 municípios sem homicídio, mas o grupo mais violento mantém os mesmos 219 municípios e a mesma composição.

Figura 4 – EM: log-verossimilhança por iteração e mistura estimada



Fonte: Elaborada pelos autores (2026).

Tabela 7 – Grupos do EM e a composição segundo o Cartografias (linhas somam 1)

Grupo	θ	hom. típicos	sem reg.	uma	disputa
$Z = 0$	0,31	3,6	0,887	0,096	0,017
$Z = 1$	0,36	9,2	0,724	0,219	0,057
$Z = 2$	0,33	23,1	0,342	0,370	0,288

Nota: θ é o peso do grupo na mistura; "hom. típicos" é o centro da gaussiana ($e^{\mu} - 1$), em homicídios somados de 2021 a 2023.

Fonte: Elaborada pelos autores com dados do SINESP/VDE, do IBGE e do *Cartografias da Violência na Amazônia* (2026).

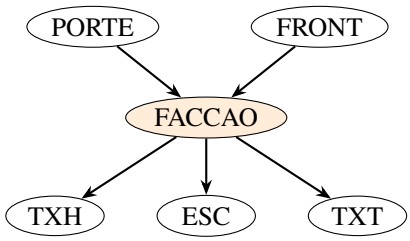
Contagem × taxa. Com a *taxa* por 100 mil habitantes no lugar da contagem, a correspondência piora: o grupo mais violento tem só 15% em disputa, e o EM leva 38 iterações. A facção acompanha o *volume* de violência, que cresce com o tamanho do mercado, e não só a intensidade relativa à população. Com a taxa há também um problema técnico: os 52 municípios sem homicídio têm exatamente o mesmo valor, e uma gaussiana tende a colapsar sobre eles, com variância indo a zero e verossimilhança ao infinito. Um piso de variância ($\sigma^2 \geq 0{,}05$) evita essa singularidade.

NB puro × NB + EM. Trocando os tercis de TXH pelo grupo Z do EM (ajustado só no treino de cada dobra), o Naive Bayes passa de 77,2% para 77,7% de acurácia (balanceada de 0,737 para 0,745). O ganho é pequeno porque Z traz o volume de violência, informação que já estava em boa parte em PORTE. A probabilidade de facção do NB + EM, calculada fora da dobra (AUC 0,84), segue para a Etapa 6.

7 Etapa 5 — Rede bayesiana

Estrutura. O grafo acíclico dirigido (DAG, do inglês *Directed Acyclic Graph*) da Figura 5 tem 6 nós. Os pais de FACCAO são os dois atributos de maior ganho na árvore da Etapa 1: PORTE e UF, esta resumida em FRONT para a tabela de probabilidade condicional (CPT, do inglês *Conditional Probability Table*) de FACCAO não ter linhas com 1 ou 2 municípios. PORTE→FACCAO: cidades maiores concentram mercado consumidor, portos, rodovias e presídios (SIQUEIRA; PAIVA, 2019). FRONT→FACCAO: as fronteiras e suas cidades são nós da rede da cocaína (COUTO, 2020). FACCAO→{TXH, ESC, TXT}: disputas e execuções elevam homicídios, tentativas e mortes sem causa esclarecida. A rede é usada no sentido diagnóstico: observamos porte, estado e sintomas e inferimos $P(\texttt{FACCAO} \mid \text{evidências})$.

Figura 5 – DAG: FACCAO é colisor de PORTE e FRONT e causa comum dos três sintomas



Fonte: Elaborada pelos autores (2026).

CPTs e economia. As CPTs são estimadas por máxima verossimilhança. A tabela central, $P(\texttt{FACCAO}{=}1 \mid \texttt{PORTE}, \texttt{FRONT})$, vai de 0,013 (pequeno, sem fronteira) a 0,861 (grande, com fronteira). A conjunta das 6 variáveis ($3 \cdot 2 \cdot 2 \cdot 3 \cdot 2 \cdot 3 = 216$ células) exige 215 parâmetros; a rede, 19: $2+1+6+4+2+4$. Economia de 196 parâmetros (91%).

Inferência por enumeração. Implementamos $P(X \mid e) = \alpha \sum_y \prod_i P(x_i \mid pais(X_i))$ do zero e comparamos com a `VariableElimination` do `pgmpy` em 7 consultas (15 probabilidades): a maior diferença é $1{,}1 \times 10^{-16}$. Exemplos: $P(F \mid \text{grande}) = 0{,}79$; $P(F \mid \text{pequeno}) = 0{,}13$; um município pequeno de fronteira com os três sintomas no nível mais alto tem $P(F) = 0{,}43$; um grande, sem fronteira e sem sintomas, 0,29.

d-separação. (1) *Garfo*: TXH←FACCAO→ESC; dado FACCAO, os sintomas são d-separados. (2) *Colisor*: PORTE→FACCAO←FRONT. Sem observar FACCAO, $P(\texttt{FRONT} \mid \text{pequeno}) = P(\texttt{FRONT} \mid \text{grande}) = 0{,}559$: independentes. Observando FACCAO=1, o caminho se abre: $P(\texttt{FRONT} \mid \text{pequeno}, F) = 0{,}955$ contra 0,608 para grande. É o *explaining away*: uma facção

num município pequeno é mais bem "explicada" pela rota do tráfico do que pelo tamanho. Nos dados, porte e fronteira têm correlação 0,21; a independência marginal suposta pelo DAG é uma aproximação.

A rede como classificador. Em 5 dobras, AUC $= 0{,}81$ (acurácia 76,1%, balanceada 0,713). As probabilidades passadas à Etapa 6 são *fora da dobra*: cada município recebe a $P(F)$ de uma rede treinada sem ele, para que a validação seguinte não seja otimista.

Rede $\times$ árvore. Com as mesmas dobras, a decisão da ID3 (Etapa 1) e a da rede ($P \geq 0{,}5$) concordam em 83% dos municípios: quando ambas dizem "facção", 76% têm; quando ambas dizem "sem", 15%. Nos 36 que só a árvore marca, 75% têm facção: ela usa a UF inteira, e a rede só `FRONT`. As duas ordenam igualmente bem (AUC 0,81). `LATRO`, 3º no ganho, como quarto sintoma quase não muda a AUC de 2024 (0,814) e piora a da entrada em 2025 (0,750 contra 0,764); fica fora.

Deixando um estado de fora. A AUC geral cai pouco (0,80), mas a tabela por estado mostra o que a média esconde (Tabela 8). A rede ordena bem os municípios em TO, AP, MA e PA, mas erra o *nível* onde a facção é quase universal: no Acre e em Roraima a P média prevista é cerca de 0,47, porque `FRONT` só distingue MA e TO dos demais. Serve para ordenar municípios num estado conhecido, não para estimar o nível num estado novo.

Tabela 8 – Validação deixando um estado de fora

UF	n	facção	P média	AUC
AC	22	1,00	0,47	–
RR	15	0,93	0,47	0,64
PA	144	0,51	0,53	0,78
RO	52	0,50	0,43	0,58
AM	62	0,32	0,32	0,65
AP	16	0,31	0,51	0,85
MT	141	0,30	0,51	0,75
MA	217	0,22	0,21	0,79
TO	139	0,06	0,11	0,94

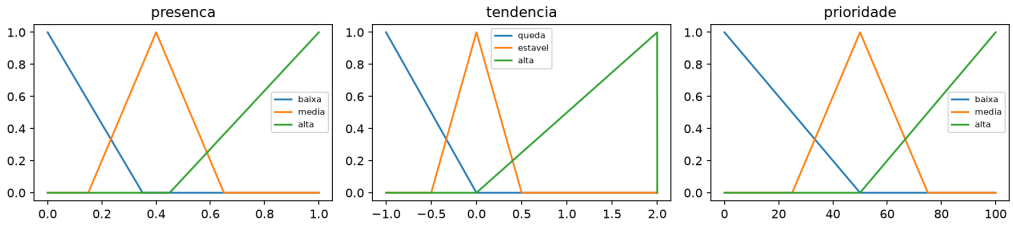
Fonte: Elaborada pelos autores (2026).

Sensibilidade ao rótulo. Sem os 45 municípios que "saíram" da lista em 2025, a AUC sobe para 0,83; a rede já os via com probabilidade intermediária (0,40, contra 0,58 dos que têm facção nas duas edições e 0,23 dos sem facção), o que é coerente com erro de registro ou mudança de método. Com o rótulo "facção em 2024 ou 2025", a AUC é 0,82. As conclusões não dependem do ruído do rótulo.

8 Etapa 6 — Lógica fuzzy e integração

Variáveis linguísticas. O sistema Mamdani (`scikit-fuzzy`), baseado na teoria dos conjuntos fuzzy (ZADEH, 1965), tem duas entradas: *presença* = média da $P(F)$ da rede (Etapa 5) e da do NB + EM (Etapa 4), ambas fora da dobra (baixa, média, alta, centradas em torno da taxa-base de 32%) e *tendência* = variação relativa dos homicídios de 2020–21 para 2022–23 (queda, estável, alta). A saída é a *prioridade* de monitoramento, de 0 a 100 (Figura 6). Todas as funções de pertinência são triangulares, que em sistemas Mamdani para nível de criminalidade classificaram melhor do que as trapezoidais (MOHAMAD NOOR; AB HAMID, 2014).

Figura 6 – Funções de pertinência



Fonte: Elaborada pelos autores (2026).

Regras.

1. SE presença alta E (tendência alta OU estável) ENTÃO prioridade alta.
2. SE presença alta E tendência em queda ENTÃO prioridade média (possível domínio consolidado).
3. SE presença média E tendência alta ENTÃO prioridade alta (possível expansão).
4. SE presença média E (estável OU queda) ENTÃO prioridade média.
5. SE presença baixa ENTÃO prioridade baixa.

A regra 2 traduz um padrão descrito na literatura: onde uma facção já domina sozinha, a violência pode cair (“paz do domínio”). A defuzzificação é pelo centroide; classificamos a saída em baixa (< 40), média (40–60) e alta (≥ 60).

Conferência com 2024 e 2025. A Tabela 9 confere a decisão com o rótulo de 2024 e com as entradas de 2025. A proporção com facção cresce de 12% para 64% da prioridade baixa para a alta, e a de disputa, de 1,6% para 28,4%. Entre os 549 sem facção em 2024, a taxa de entrada em 2025 vai de 14% na baixa para 45% na alta. É uma validação fora do tempo: nenhum dado de 2025 foi usado.

A média com o NB + EM melhora a ordenação de 2024 (o NB usa a UF inteira), mas não a da entrada em 2025: a prevalência do estado diz onde a facção está, não para onde vai.

Fuzzy $\times$ limiar rígido. O limiar presença $\geq 0{,}5$ divide os municípios em 242 “alta” e 566 “baixa”. Ele também separa bem (entrada em 2025: 47% contra 20%), mas joga numa só classe os 471 sem facção que ficaram abaixo do limiar. O fuzzy cria uma faixa intermediária de 146 municípios que já concentra 42% de entradas, e a saída é contínua perto da fronteira de decisão

Tabela 9 – Prioridade fuzzy conferida com o rótulo de 2024 e com as entradas de 2025

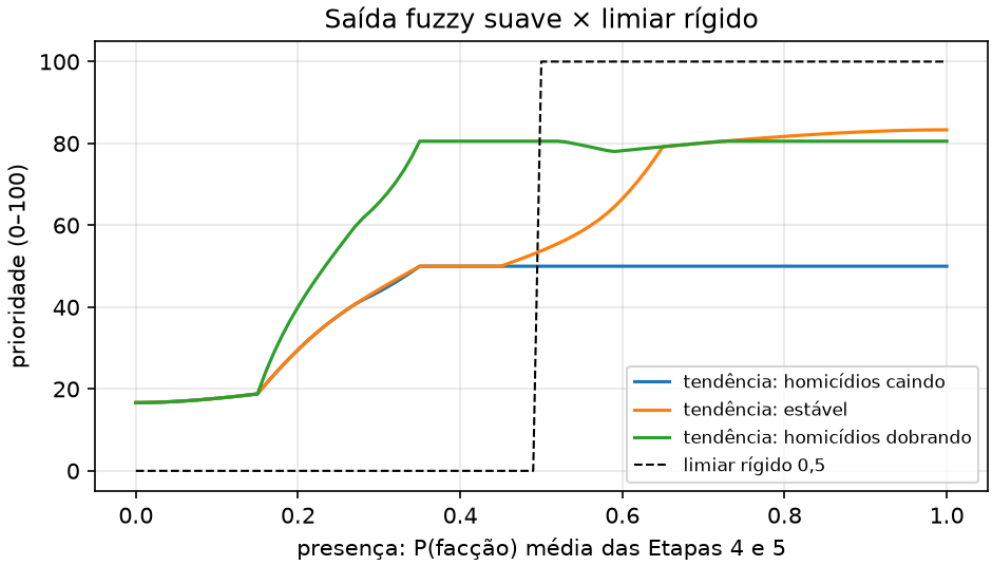
Prioridade	Munic.	Facção 2024	Disputa	Entrada 2025*
Baixa	426	12,4%	1,6%	13,9%
Média	146	37,0%	7,5%	42,4%
Alta	236	64,4%	28,4%	45,2%

Nota: *entre os municípios sem facção em 2024. AUC (facção 2024 / entrada 2025): rede 0,809 / 0,764; NB + EM 0,840 / 0,728; presença (média) 0,836 / 0,753; prioridade fuzzy 0,815 / 0,749.

Fonte: Elaborada pelos autores (2026).

(Figura 7): um município com $P = 0{,}49$ e outro com 0,51 recebem prioridades próximas, não opostas. Isso importa aqui porque o rótulo é ruidoso ("sem registro" não é ausência certa) e a fronteira entre as classes é ambígua: são exatamente os casos em que o fuzzy supera o limiar rígido. A tendência também desloca a prioridade, o que um limiar sobre P não faz.

Figura 7 – Prioridade fuzzy em função de $P(F)$ para três tendências, contra o limiar rígido



Fonte: Elaborada pelos autores (2026).

A violência de 2024 antecipa a chegada? Com o VDE de 2024, testamos duas hipóteses com uma regressão logística em 5 dobras, só entre os sem facção em 2024. (i) Trocar a janela 2021–23 por 2022–24 não melhora (AUC 0,754 nas duas). (ii) Municípios cujos homicídios saltaram em 2024 entraram mais (31% contra 21%), mas o salto de 2023 tem o mesmo efeito (32% contra 21%). O salto é sinal de município violento, não da chegada da facção. Estudos de caso, como o de Iranduba (AM), em que os homicídios subiram 318% em 2021 após a criação de uma facção (SALES et al., 2025), não aparecem como padrão na escala dos 808 municípios.

Interpretabilidade. Cada regra é uma frase que um analista de inteligência entende e pode contestar, e cada entrada tem origem rastreável: a presença vem da rede e do Naive Bayes (ambos tabelas de frequência) e a tendência vem direto do VDE.

9 Discussão

A Tabela 10 compara os resultados com as faixas de referência do enunciado. Ficamos dentro ou acima nas Etapas 1 e 2 (regressão). Ficamos abaixo na logística e no NB + EM. A razão é o próprio problema: a taxa-base é 32%, os atributos públicos (violência e população) só capturam parte do fenômeno e o rótulo só tem positivos confiáveis (Seção 11). A AUC de 0,81 mostra que os modelos ordenam bem os municípios; o que limita a acurácia é a sobreposição real entre municípios violentos sem facção e facções que dominam sem violência. O EM atinge o critério de parada em 5 iterações (contagem) ou 38 (taxa), fora da faixa de 15–30, porque a tolerância é relativa (10^{-4}). Com uma tolerância mais rígida (10^{-6}) ele vai a 358 iterações, sem mudar o grupo mais violento, que é o que importa para a facção; a curva cresce monotonicamente, como esperado.

Outras variáveis. Testamos ainda 15 variáveis de outras bases (IBGE, INPE, IBAMA), trocando um nó da rede (`experimentos_variaveis.ipynb`). Nenhuma melhorou a AUC de 2024 em mais de 0,01, e placebos como suicídio e trânsito renderam tanto quanto a violência: os sintomas carregam sobretudo o tamanho do município. A faixa de fronteira por município corrige o erro de nível no Acre e em Roraima (AUC 0,84), mas piora a previsão de 2025 (0,71), porque a expansão foi tão frequente no interior quanto na faixa; por isso mantivemos `FRONT` por estado.

Tabela 10 – Resultados obtidos × faixas de referência do enunciado

Métrica	Esperado	Obtido
Árvore: treino sem poda	85–92%	87,4%
Árvore: teste 5-fold	72–80%	78,6%
Profundidade ótima	3–5	3–5
R^2 simples	0,55–0,65	0,672
R^2 multivariada	0,70–0,80	0,763
R^2 Ridge	0,72–0,82	0,762
Logística	78–85%	75,9%
Naive Bayes puro	72–78%	77,2%
Naive Bayes + EM	80–86%	77,7%
Enumeração = `pgmpy`	idêntico	dif. 10^{-16}

Fonte: Elaborada pelos autores (2026).

O fio condutor do pipeline é a passagem da certeza à incerteza graduada. A árvore produz regras legíveis, mas a monotonicidade mostra que elas quebram com um fato novo. A probabilidade substitui "é/não é" por graus de crença; o EM mostra que a variável oculta deixa rastro

nos dados; a rede organiza essas crenças com poucos parâmetros e permite raciocinar nos dois sentidos; e o fuzzy devolve uma decisão legível, agora sem fronteiras rígidas.

10 Comunicação

Houve comunicação com a equipe 5 sobre o trabalho:

Equipe 5 — Segurança Pública: Nosso projeto utiliza indicadores oficiais de segurança pública para aplicar técnicas de Inteligência Artificial, incluindo árvores de decisão, regressão, inferência probabilística, estimação estatística, redes Bayesianas e lógica fuzzy. Buscamos identificar situações de elevado volume de ocorrências que possam demandar maior atenção da gestão pública.

Equipe 1 — Facções Criminosas na Amazônia Legal: Nosso estudo investiga a presença e a expansão de facções criminosas nos municípios da Amazônia Legal. Utilizamos rótulos provenientes das Cartografias, 3ª e 4ª edições, e atributos extraídos do Banco VDE do SINESP/MJSP, abrangendo o período de 2020 a 2024. Também integramos informações populacionais do IBGE e indicadores externos do IBAMA, INPE e IBGE.

Equipe 5 — Segurança Pública: Uma diferença importante entre os projetos está na unidade de análise. Trabalhamos com indicadores agregados por unidade federativa e período, enquanto vocês utilizam informações municipais. A granularidade municipal pode permitir análises territoriais mais específicas, embora exija cuidados adicionais com a qualidade e a integração dos dados.

Equipe 1 — Facções Criminosas na Amazônia Legal: Exatamente. Nossa metodologia utiliza códigos municipais para integrar diferentes fontes. Além dos registros de violência, consideramos variáveis territoriais e ambientais que podem contribuir para investigar associações com a presença de facções. Essas associações, entretanto, não devem ser interpretadas automaticamente como relações causais.

Equipe 5 — Segurança Pública: Essa abordagem oferece uma perspectiva complementar à nossa. As técnicas probabilísticas e de classificação utilizadas em nosso trabalho poderiam, em estudos futuros, ser aplicadas a indicadores municipais para investigar padrões territoriais, desde que fossem realizados novos treinamentos e validações.

Equipe 1 — Facções Criminosas na Amazônia Legal: Da mesma forma, a utilização de redes Bayesianas e lógica fuzzy poderia contribuir para representar incertezas e produzir classificações interpretáveis. Entretanto, seria necessário avaliar a qualidade dos rótulos e os riscos de generalização indevida dos resultados.

Equipe 5 — Segurança Pública: Concluímos que os projetos são complementares: enquanto nossa pesquisa analisa indicadores agregados de segurança pública para apoiar o monitoramento, o estudo de vocês investiga padrões municipais relacionados à presença e à expansão de facções

criminosas. A integração dessas perspectivas poderia fundamentar pesquisas futuras sobre análise territorial e apoio à decisão pública.

Síntese: A comparação evidencia a importância da granularidade territorial, da integração de bases oficiais, da interpretação probabilística e da validação dos modelos. Também demonstra que indicadores de violência e presença de organizações criminosas representam fenômenos distintos, que não devem ser tratados como equivalentes.

11 Conclusão e limitações

O porte do município e o estado explicam a maior parte da presença registrada de facção na Amazônia Legal; a violência refina essa estimativa. A probabilidade calculada com dados até 2023 antecipa parte da expansão observada em 2025 (AUC 0,76), mas a violência indica onde a facção tende a estar, não quando ela chega. Das 15 variáveis de outras bases que testamos, nenhuma melhorou os modelos de forma consistente; o limite parece estar no rótulo, não na falta de atributos.

Limitações. (1) "Sem registro" no Cartografias significa facção não identificada pelos pesquisadores, não ausência certa; por isso falamos em facção registrada. Formalmente, é aprendizado com positivos e não rotulados (ELKAN; NOTO, 2008): se os registros fossem uma amostra aleatória dos municípios com facção, a probabilidade estimada diferiria da verdadeira por um fator constante. A ordenação (e a AUC) se preservaria, mas o nível e a acurácia ficariam subestimados. (2) Parte das mudanças entre a 3ª e a 4ª edição vem da melhoria do método; 45 municípios "saíram" da lista. (3) O relatório tem pequenas divergências entre as tabelas por estado e o quadro-resumo (AP, PA, TO); definimos "disputa" pelo número de facções listadas. (4) O Maranhão entra inteiro (217 municípios), mas só 181 pertencem à Amazônia Legal. (5) `FRONT` é definido por estado; a versão por município corrige o erro de nível em AC e RR, mas piora a previsão de 2025 (Seção 9). (6) Não há estimativa do IBGE para 2023; as taxas usam o Censo 2022.

Ética. A saída é uma prioridade estatística para orientar monitoramento, não uma acusação. Modelos treinados com registros de fiscalização tendem a prever onde há fiscalização, e não só onde há crime (LUM; ISAAC, 2016); isso vale também para o Cartografias. Municípios com prioridade alta e sem registro (por exemplo, Oriximiná, PA, com $P = 0{,}92$) são candidatos a verificação, não municípios "dominados": como nos "falsos positivos" do estudo sobre a máfia italiana (CAMPEDELLI; DANIELE; LE MOGLIE, 2024), podem ser municípios com facção ainda não registrada. Rotular publicamente uma localidade pode gerar estigma e afetar investimento e turismo; por isso a lista de candidatos fica restrita ao notebook.

Referências

CAMPEDELLI, G. M.; DANIELE, G.; LE MOGLIE, M. **Mafia, politics and machine predictions**. London: Centre for Economic Policy Research, 2024. (CEPR Discussion Paper, 19322).

CHAGAS, R. P. O "narcogarimpo" na Terra Indígena Yanomami. **Boletim de Análise Político-Institucional**, n. 36, 2024. DOI: 10.38116/bapi36art7.

COUTO, A. C. O. Fronteiras e estrutura espacial do narcotráfico na Amazônia. **Boletim Gaúcho de Geografia**, v. 47, n. 1, 2020.

COUTO, A. C. O. Relações transfronteiriças do narcotráfico na Amazônia: dos crimes conexos aos desafios da segurança regional. **Boletim de Análise Político-Institucional**, n. 36, 2024. DOI: 10.38116/bapi36art5.

ELKAN, C.; NOTO, K. Learning classifiers from only positive and unlabeled data. In: **Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. New York: ACM, 2008. p. 213–220.

HÜLLERMEIER, E. Fuzzy machine learning and data mining. **WIREs Data Mining and Knowledge Discovery**, v. 1, n. 4, p. 269–283, 2011.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **Censo Demográfico 2022, Estimativas da População, Municípios da Faixa de Fronteira 2024, Malha Municipal e REGIC 2018**. Rio de Janeiro: IBGE, 2024. Disponível em: <https://www.ibge.gov.br>. Acesso em: nov. 2026.

INSTITUTO BRASILEIRO DO MEIO AMBIENTE E DOS RECURSOS NATURAIS RENOVÁVEIS. **Dados abertos**: autos de infração e termos de destruição. Brasília: IBAMA, 2026. Disponível em: <https://dadosabertos.ibama.gov.br>. Acesso em: nov. 2026.

INSTITUTO MÃE CRIOULA; FÓRUM BRASILEIRO DE SEGURANÇA PÚBLICA. **Cartografias da violência na Amazônia**. 3. ed. São Paulo: FBSP, 2024.

INSTITUTO MÃE CRIOULA; FÓRUM BRASILEIRO DE SEGURANÇA PÚBLICA. **Cartografias da violência na Amazônia**. 4. ed. São Paulo: FBSP, 2025.

INSTITUTO NACIONAL DE PESQUISAS ESPACIAIS. **DETER Amazônia**: Terrabrasilis. São José dos Campos: INPE, 2026. Disponível em: <https://terrabrasilis.dpi.inpe.br>. Acesso em: nov. 2026.

LUM, K.; ISAAC, W. To predict and serve? **Significance**, v. 13, n. 5, p. 14–19, 2016.

MINISTÉRIO DA JUSTIÇA E SEGURANÇA PÚBLICA. **Banco VDE (SINESP)**: estatísticas de violência por município, 2020–2024. Brasília: MJSP, 2024. Disponível em: <https://dadosabertos.mj.gov.br>. Acesso em: out. 2026.

MOHAMAD NOOR, N. M.; AB HAMID, S. H. Comparison of triangular and trapezoidal membership functions for improving decision making in crime prevention. **Frontiers in Artificial Intelligence and Applications**, v. 261, 2014. DOI: 10.3233/978-1-61499-399-5-69.

RIBEIRO, J. et al. Prediction of homicides in urban centers: a machine learning approach. In: **Intelligent Systems Conference (IntelliSys)**. [S.l.: s.n.], 2021. ArXiv:2008.06979.

RUSSELL, S.; NORVIG, P. **Artificial intelligence**: a modern approach. 4. ed. Hoboken: Pearson, 2020.

SALES, P. V. A. et al. O impacto da criação da facção Revolucionários do Amazonas (RDA) nos índices de violência letal em Iranduba-AM no período de 2017 a 2024. **Revista Geopolítica Transfronteiriça**, v. 9, n. 4, p. 1–15, 2025.

SIQUEIRA, Í. B. L.; PAIVA, L. F. S. "No Norte tem Comando": as maneiras de fazer o crime, a guerra e o domínio das prisões do Amazonas. **Revista Brasileira de Sociologia**, v. 7, n. 17, p. 125–154, 2019. DOI: 10.20336/rbs.486.

ZADEH, L. A. Fuzzy sets. **Information and Control**, v. 8, n. 3, p. 338–353, 1965.

1 Uso de assistente de IA

Usamos um assistente de IA (Claude, via Claude Code) como apoio à implementação do código e à análise estatística, e para revisar parte do texto. As decisões do trabalho (a pergunta de pesquisa, a escolha dos atributos, o protocolo de validação e a interpretação dos resultados) foram da equipe. Todo o código foi lido, executado e conferido por nós, e os números do relatório vêm da execução dos notebooks com `seed = 42`.

Preparação dos dados. O assistente ajudou a escrever os scripts que montam a base municipal do VDE (2020–2024) e a juntam à população do IBGE pelo código do município, a extrair do PDF do Cartografias 2025 os quadros de facções por estado (`extrair_cartografias_2025.py`) e a agregar por município as bases externas usadas na Seção 9 (`montar_bases_externas.py`).

Implementação dos algoritmos. Com o assistente, implementamos do zero o ID3, a regressão com gradiente descendente, a regressão logística, o Naive Bayes, o EM para mistura de gaussianas e a inferência por enumeração na rede bayesiana. Cada implementação foi comparada com a biblioteca correspondente (scikit-learn e `pgmpy`); a coincidência dos resultados, por exemplo a diferença máxima de 10^{-16} na enumeração, serviu de verificação do código.

Análise estatística. O assistente auxiliou a tornar a validação mais rigorosa: tercis calculados apenas no treino de cada dobra, probabilidades da rede obtidas fora da dobra, validação deixando um estado de fora e validação fora do tempo com a 4ª edição do Cartografias. Também ajudou a organizar os experimentos com as 15 variáveis candidatas (`experimentos_variaveis.ipynb`), os testes de hipótese e as tabelas comparativas do relatório.

Revisão bibliográfica e entrega. O assistente sugeriu artigos relacionados ao tema; títulos, autores e trechos citados foram conferidos por nós nos PDFs. Ele também ajudou a preparar o relatório em LaTeX, o README e os notebooks para a entrega.

2 Reprodução

`pip install -r requirements.txt`; `python utils.py`; executar `etapa1.ipynb` a `etapa6.ipynb` em ordem (a Etapa 5 grava <dados/probabilidades_bayesianas.csv>, lido pela Etapa 6). Repositório: <https://github.com/RomarioAndrade/seguranca-publica-ml-fuzzy>.