Do Simbólico à Incerteza: inferindo a presença e a expansão de facções criminosas nos municípios da Amazônia Legal

Equipe 1 — P3 Segurança Pública

Gabriel Menezes Rodrigues, Luiz Felipe Gonzaga do Carmo, Joshua Tadeu Bastos Pereira,

Romário Roberto de Pádua Andrade, Ruan Pablo Nascimento de Aragão, Fernando Teles dos Reis

Fundamentos de Inteligência Artificial — Prof. Edjard Mota — IComp/UFAM, 2026/2

Novembro de 2026

Resumo

A presença de facções criminosas não aparece em nenhuma base oficial: é uma variável oculta. Combinamos as estatísticas de violência do SINESP VDE (2020–2024) e a população do IBGE para inferi-la nos 808 municípios dos estados da Amazônia Legal, usando como referência o *Cartografias da Violência na Amazônia* de 2024. Percorremos as seis etapas do pipeline: árvore de decisão, modelos lineares, probabilidade, Naive Bayes com EM, rede bayesiana e lógica fuzzy. A rede bayesiana diagnóstica atinge AUC de 0,81 (0,80 testando num estado que não viu). Sem usar nenhum dado de 2025, a probabilidade calculada antecipa quais municípios passaram a ter facção segundo a edição de 2025 (AUC 0,76): na prioridade fuzzy baixa, 14% entraram; na alta, 45%. A violência indica onde a facção tende a estar, mas não quando ela chega.

1 Introdução

Nas duas últimas décadas, facções criminosas nascidas no Sudeste (PCC e Comando Vermelho) e grupos regionais se espalharam pela Amazônia, atraídos pelas rotas fluviais e terrestres da cocaína produzida na Bolívia, no Peru e na Colômbia [11] e pelo sistema prisional, onde se organizam [10]. A literatura descreve uma interiorização das facções na região, ligada também ao garimpo ilegal [12, 13]. O *Cartografias da Violência na Amazônia*, do Fórum Brasileiro de Segurança Pública com o Instituto Mãe Crioula, mapeia município a município quais facções atuam na região: na 3ª edição (dados de 2024) havia registro em 259 dos 808 municípios dos nove estados; na 4ª edição (2025), em 344.

Esse mapeamento depende de trabalho de campo e de fontes policiais e não é atualizado continuamente. As estatísticas de violência, por outro lado, são publicadas todo ano pelo Ministério da Justiça. Trabalhos próximos usam aprendizado de máquina para prever homicídios em Belém a partir de boletins de ocorrência [16] e para prever a infiltração mafiosa em municípios italianos com validação fora do tempo [17]; neste último, os "falsos positivos" se parecem com municípios infiltrados ainda não detectados, ponto que retomamos na Seção 12. A pergunta deste trabalho é:

> *O município da Amazônia Legal tem presença de facção criminosa (2024), dado o seu porte e o padrão de violência registrado entre 2021 e 2023? E o modelo antecipa quais municípios passaram a ter facção em 2025?*

A resposta final é uma prioridade de monitoramento por município, produzida por um sistema fuzzy que recebe as probabilidades das Etapas 4 e 5. A prioridade não é uma acusação: indica onde a inteligência policial teria mais chance de encontrar atuação de facção.

2 Dados e protocolo de validação

Fontes. (i) Rótulos: Cartografias, 3ª edição [4] (Tabelas 13–21, presença em 2024) e 4ª edição [5] (quadros por estado, extraídos do PDF com `extrair_cartografias_2025.py`). (ii) Atributos: Banco VDE do SINESP/MJSP [6], 2020–2024, por município (homicídio doloso, tentativa, morte a esclarecer, latrocínio, mandados). (iii) População: IBGE, Censo 2022 e estimativas [7], unida pelo código do município. Os 5.570 municípios do VDE casaram com o IBGE; os 808 dos 9 estados casaram com o Cartografias. (iv) Bases externas, usadas na análise do garimpo e nos experimentos (Seção 9): autos de infração e termos de destruição do IBAMA [8], alertas do DETER/INPE [9], faixa de fronteira, malha municipal e REGIC do IBGE [7], todos de 2021–23 e agregados por município (`montar_bases_externas.py`). Dos arquivos do IBAMA, que identificam os autuados, guardamos só contagens por município.

Atributos. Para a árvore, o Naive Bayes e a rede, usamos atributos discretos e interpretáveis (Tabela 1). As taxas são médias anuais de 2021–23 por 100 mil habitantes (Censo 2022).

Validação. Sempre com `seed = 42`: (a) validação cruzada estratificada de 5 dobras, recalculando os tercis de `TXH` e `TXT` com os cortes do treino de cada dobra, para o teste não influenciar a discretização; (b) *deixando um estado de fora* (treina com 8, testa no 9º); (c) *fora do tempo*: entre os 549 municípios sem facção em 2024, quais passaram a ter em 2025, rótulo que nenhum modelo

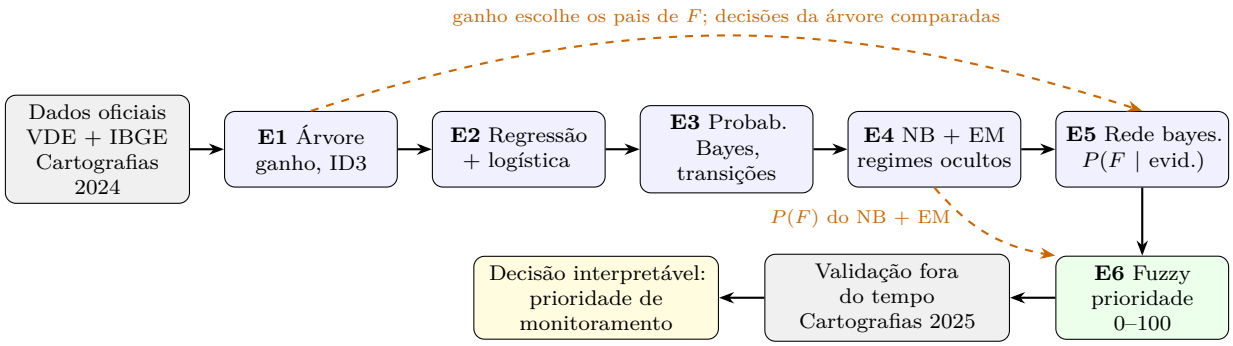


Figura 1: Pipeline integrado. As setas tracejadas indicam reutilização: o ganho da Etapa 1 define os pais de `FACCAO` na rede, cujas decisões são comparadas às da árvore; a $P(F)$ do Naive Bayes + EM (Etapa 4) entra, com a da rede, na presença do sistema fuzzy.

Variável	Definição
`PORTE`	pequeno (<10 mil), médio (10–50 mil), grande (50 mil+)
`TXH`	taxa de homicídio 2021–23, em tercis
`TXT`	taxa de tentativas de homicídio 2021–23, em tercis
`ESC`	teve morte a esclarecer em 2021–23
`LATRO`	teve latrocínio em 2021–23
`UF/FRONT`	estado / estado faz fronteira com outro país
`ALVO`	facção registrada em 2024 (32,1%)

Tabela 1: Atributos e alvo.

	`PORTE`	`UF`	`LATRO`	`ESC`	`TXH`	`TXT`
Ganho	**0,165**	0,151	0,070	0,030	0,027	0,017

Tabela 2: Ganho de informação na raiz (nível 1).

Modelo	Treino	Teste	Bal.
ID3 própria, sem poda	0,874	0,749	0,687
ID3 própria, prof. 3	0,824	**0,786**	**0,708**
sklearn, sem poda	0,875	0,745	0,683
sklearn, prof. 4	0,799	0,782	0,679

Tabela 3: Validação cruzada 5-fold (tercis calculados no treino de cada dobra).

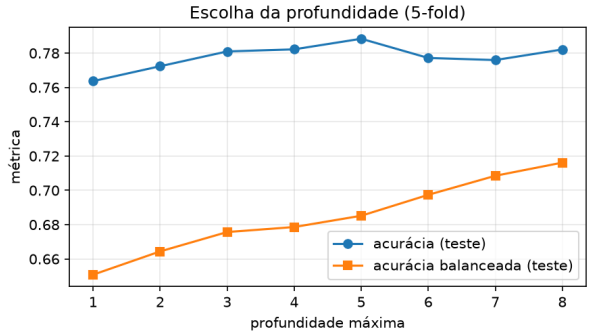


Figura 2: Acurácia de teste por profundidade máxima.

viu. Como as classes são desbalanceadas ("sempre não" acerta 67,9%), reportamos também acurácia balanceada e AUC.

3 Etapa 1 — Árvore de decisão

Entropia e ganho (cálculo manual). Na raiz, 259 dos 808 municípios têm facção: $H = -\frac{259}{808}\log_2\frac{259}{808} - \frac{549}{808}\log_2\frac{549}{808} = 0{,}905$ bits. Para `PORTE`, os filhos são pequeno (27/267 com facção, $H = 0{,}473$), médio (145/435, $H = 0{,}918$) e grande (87/106, $H = 0{,}678$). A entropia ponderada é $(267 \cdot 0{,}473 + 435 \cdot 0{,}918 + 106 \cdot 0{,}678)/808 = 0{,}740$, e o ganho é $0{,}905 - 0{,}740 = 0{,}165$, o maior entre os seis atributos (Tabela 2).

No **nível 2**, em todos os três ramos de porte o melhor atributo é `UF`: ganho de 0,167 entre os pequenos ($H = 0{,}473$), 0,133 entre os médios ($H = 0{,}918$) e 0,044 entre os grandes ($H = 0{,}678$). No **nível 3**, os atributos de violência finalmente aparecem: nos médios do Mato Grosso ($n = 61$, $H = 0{,}929$) o melhor é `TXT` (ganho 0,135); nos médios de Rondônia ($n = 23$, $H = 0{,}999$) e do Amazonas ($n = 48$, $H = 0{,}696$), `TXH` (0,164 e 0,107); nos médios do Maranhão ($n = 153$) e do Pará ($n = 90$), `LATRO` (0,040 e 0,035). A árvore diz, portanto, que o tamanho do município e o estado explicam a maior parte da presença de facção; a violência refina a decisão dentro de cada estado.

Implementação e validação. Implementamos o Learn-Decision-Tree (ID3) do zero e comparamos com o `DecisionTreeClassifier` (critério entropia) em 5 dobras (Tabela 3). As duas implementações sem poda dão o mesmo resultado (0,749 e 0,745). A poda por profundidade reduz o sobreajuste: o treino cai de 87% para 82% e o teste sobe para 78,6%. A Figura 2 mostra a curva de profundidade.

Monotonicidade. A regra mais simples sugerida pelos dados é $\forall x\,(\mathit{Pequeno}(x) \rightarrow \neg \mathit{Facção}(x))$. Ela cobre 267 municípios e acerta 89,9%. Mas, ao acrescentarmos um único fato novo, "o município fica no Acre" ou "em Roraima", a conclusão se inverte: todos os pequenos desses estados têm facção (3 de 3 e 2 de 2), e em Rondônia 9 de 22. São estados de fronteira, na rota da cocaína, onde a facção chega até às cidades pequenas. Na lógica clássica, o raciocínio é monotônico: se a regra foi aceita como axioma, nenhum fato novo a derruba, e

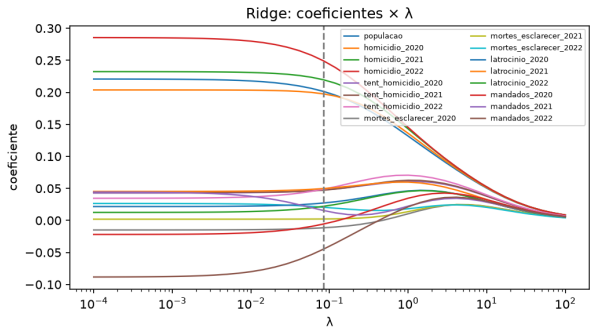


Figura 3: Coeficientes do Ridge em função de λ.

Modelo	R^2	Acurácia (bal.)
Simples (hom. 2022 → 2023)	0,672	–
Multivariada (GD, 16 atributos)	0,763	–
Ridge ($\lambda = 0{,}084$)	0,762	–
Logística (facção)	–	0,759 (0,737)

Tabela 4: Resultados no teste (20%). O scikit-learn dá os mesmos valores.

a base passaria a ser inconsistente. No mundo real, a informação nova invalida a conclusão anterior. Esse é o limite das regras rígidas que motiva as etapas seguintes, em que as conclusões são graus de crença revisáveis.

4 Etapa 2 — Modelos lineares

Regressão. Como alvo contínuo usamos $y = \log(1 + \text{homicídios em 2023})$. Os 16 atributos são log(população) e as contagens de 2020–2022 (em $\log(1+x)$). Divisão 80/20. A regressão univariada por fórmula fechada sobre os homicídios de 2022 dá $\hat{y} = 0{,}282 + 0{,}812\,x$ ($R^2 = 0{,}672$). A multivariada com gradiente descendente do zero (atributos padronizados, $\alpha = 0{,}05$, 5.000 iterações) chega a $R^2 = 0{,}763$. Como os 16 atributos são muito correlacionados (o mesmo evento em três anos seguidos), aplicamos Ridge: o λ escolhido por validação cruzada é 0,084, com $R^2 = 0{,}762$ (Figura 3). À medida que λ cresce, os coeficientes encolhem e deixam de oscilar entre anos correlacionados.

Logística. Para o problema da Etapa 1, implementamos a regressão logística (sigmoide + gradiente, com pesos de classe balanceados). Acurácia de 75,9% e balanceada de 0,737, idênticas ao `LogisticRegression`. Todos os modelos próprios coincidem com o scikit-learn até a terceira casa (Tabela 4).

5 Etapa 3 — Probabilidade

Cada município é um "mundo". Definimos F = tem facção em 2024; V = taxa de homicídio no tercil mais alto; E = teve morte a esclarecer. A conjunta de F e V está na Tabela 5.

Bayes: causal × diagnóstico. O sentido *causal* é $P(V \mid F)$: a facção provoca disputas e execuções. Nos

	$F=0$	$F=1$	$P(V)$
$V=0$	0,4876	0,1795	0,6671
$V=1$	0,1918	0,1411	0,3329
$P(F)$	0,6795	0,3205	1,0000

Tabela 5: Distribuição conjunta (4 eventos atômicos).

2024 \ 2025	sem reg.	uma	disputa	total
sem registro	420	111	18	549
uma facção	32	126	16	174
disputa	13	18	54	85

Tabela 6: Regimes de facção em 2024 e 2025 (municípios).

dados, $P(V{=}1 \mid F{=}1) = 0{,}440$. O analista, porém, observa o efeito e quer a causa oculta, o sentido *diagnóstico*:

$$P(F \mid V) = \frac{P(V \mid F)\,P(F)}{P(V)} = \frac{0{,}440 \times 0{,}3205}{0{,}3329} = 0{,}424,$$

contra $P(F \mid \neg V) = 0{,}269$: a taxa alta multiplica a chance por 1,6. A conferência direta na tabela dá o mesmo valor.

Regra da cadeia. $P(F, V, E) = P(F)\,P(V \mid F)\,P(E \mid F, V)$ reproduz exatamente as 8 probabilidades conjuntas (soma 1). **Independência condicional.** Testamos se V e E são independentes dado F: para $F = 0$, $P(V, E \mid F) = 0{,}204$ contra o produto 0,167 ($\chi^2 = 14{,}5$, $p < 10^{-3}$); para $F = 1$, 0,386 contra 0,350 ($p = 0{,}006$). A hipótese do Naive Bayes é violada: os dois sintomas compartilham uma causa que não está no modelo (o volume de violência).

Por que a LPO não diz "42% de chance". A fórmula $\forall x\,(\mathit{ViolênciaAlta}(x) \rightarrow \mathit{Facção}(x))$ é falsa, porque há municípios violentos sem facção; a sua negação também não serve. A lógica de primeira ordem só atribui verdadeiro ou falso; para dizer "em 42% dos casos" é preciso uma medida de crença, que é a probabilidade.

Transições 2024 → 2025. Com a 4ª edição, a distribuição conjunta dos regimes nos dois anos (Tabela 6) mostra a dinâmica. Dos 549 municípios sem registro em 2024, 129 (23,5%) passaram a ter facção em 2025, e a chance cresce com o porte: 13,8% nos pequenos, 30,7% nos médios e 36,8% nos grandes. Por Bayes, $P(\text{entrada} \mid \text{grande}) = 0{,}054 \times 0{,}235/0{,}035 = 0{,}368$. Também há 45 "saídas", o que sugere que parte da mudança vem do método, como o próprio relatório admite.

Garimpo e a entrada em 2025. O garimpo ilegal é descrito como uma das economias exploradas pelas facções na região, no que se convencionou chamar de "narcogarimpo" [13, 14]. Medimos o garimpo em 2021–23 por duas fontes independentes: auto de infração do IBAMA por garimpo ou mineração ilegal (71 municípios) e alerta do DETER/INPE da classe mineração (76). Entre os 549 sem facção em 2024 (Tabela 7), os que tinham garimpo tiveram o dobro de entradas em 2025 nas duas

Entrada em 2025	IBAMA	INPE
Com garimpo	45,2%	44,7%
Sem garimpo	21,7%	21,9%
Médios com garimpo	55,6% ($n = 27$)	60,0% ($n = 25$)
Médios sem garimpo	28,1%	27,9%

Tabela 7: Entrada de facção em 2025 entre os municípios sem facção em 2024, segundo o garimpo em 2021–23.

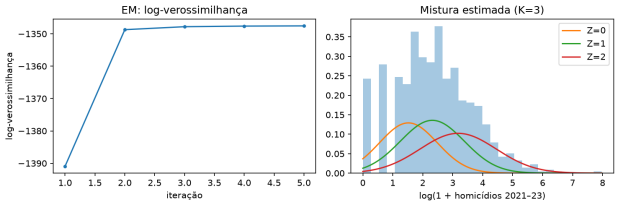


Figura 4: EM: log-verossimilhança por iteração e mistura estimada.

fontes (teste exato de Fisher, $p = 0{,}001$ e 0,003). Por Bayes, com a fonte IBAMA, $P(\text{entrada} \mid G) = P(G \mid \text{entrada})P(\text{entrada})/P(G) = 0{,}147 \times 0{,}235/0{,}077 = 0{,}45$. Já a associação com a facção *existente* em 2024 é fraca: pelo IBAMA, dentro do mesmo porte, não há diferença (médios: 37% contra 33%). O garimpo sinaliza *para onde* a facção vai, o que a violência não capta (Seção 8). Cuidados: autuação também reflete onde houve fiscalização, e o DETER inclui mineração legal.

6 Etapa 4 — MLE, MAP, Naive Bayes e EM

MLE e MAP. Para $\theta = P(\text{facção})$ por estado, $\hat{\theta}_{MLE} = k/n$ e, com prior Beta(2,2), $\hat{\theta}_{MAP} = (k + 1)/(n + 2)$. Onde há poucos municípios, o MLE é extremo: no Acre ($k = n = 22$), $\hat{\theta}_{MLE} = 1$, o que daria probabilidade zero a um município sem facção; o MAP dá 0,958. Em Roraima, 0,933 contra 0,882. Nos estados grandes (PA, MA, MT) os dois coincidem até a segunda casa: o prior só pesa quando há pouca evidência.

Naive Bayes do zero. Com suavização de Laplace e os seis atributos da Etapa 1, acurácia de 77,2% e balanceada de 0,737 em 5 dobras, igual ao `CategoricalNB`.

EM com variável oculta. O Cartografias classifica cada município em "sem registro", "uma facção (domínio)" ou "disputa". Supomos que esse regime Z é oculto e tentamos recuperá-lo só a partir de $x = \log(1+\text{homicídios 2021–23})$, com uma mistura de 3 gaussianas ajustada pelo EM (`em.py`). A log-verossimilhança cresce monotonicamente e estabiliza em 5 iterações (Figura 4). O EM nunca vê o rótulo, mas os grupos acompanham o Cartografias (Tabela 8): no grupo menos violento, 1,7% estão em disputa; no mais violento, 29%.

Com a *taxa* por 100 mil no lugar da contagem, a correspondência é mais fraca (o grupo mais violento tem 15% em disputa), e o EM leva 38 iterações. A facção está ligada ao *volume* de violência, que acompanha o tamanho do mercado, e não só à intensidade relativa. Com a taxa, uma componente tenta colapsar sobre os municípios sem nenhum homicídio; um piso de variância ($\sigma^2 \geq 0{,}05$) evita a singularidade.

Grupo	θ	hom. típicos	sem reg.	uma	disputa
$Z = 0$	0,31	3,6	0,887	0,096	0,017
$Z = 1$	0,36	9,2	0,724	0,219	0,057
$Z = 2$	0,33	23,1	0,342	0,370	0,288

Tabela 8: Grupos do EM e a composição segundo o Cartografias (linhas somam 1).

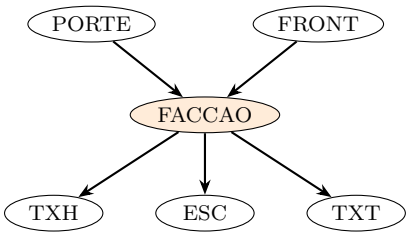


Figura 5: DAG: `FACCAO` é colisor de `PORTE` e `FRONT` e causa comum dos três sintomas.

NB puro × NB + EM. Trocando os tercis de `TXH` pelo grupo Z (ajustado só no treino de cada dobra), o Naive Bayes passa de 77,2% para 77,7% (balanceada de 0,737 para 0,745). O ganho é pequeno: Z traz o volume de violência, mas boa parte dessa informação já estava em `PORTE`. A $P(F)$ do NB + EM, calculada fora da dobra (AUC 0,84), é gravada para a Etapa 6.

7 Etapa 5 — Rede bayesiana

Estrutura. O DAG (Figura 5) tem 6 nós. Os pais de `FACCAO` são os dois atributos de maior ganho na árvore da Etapa 1: `PORTE` e `UF`, esta resumida em `FRONT` para a CPT não ter linhas com 1 ou 2 municípios. `PORTE`→`FACCAO`: cidades maiores concentram mercado consumidor, portos, rodovias e presídios [10]. `FRONT`→`FACCAO`: as fronteiras e suas cidades são nós da rede da cocaína [11]. `FACCAO`→{`TXH`, `ESC`, `TXT`}: disputas e execuções elevam homicídios, tentativas e mortes sem causa esclarecida. A rede é usada no sentido diagnóstico: observamos porte, estado e sintomas e inferimos $P(\texttt{FACCAO} \mid \text{evidências})$.

CPTs e economia. As CPTs são estimadas por máxima verossimilhança. A tabela central, $P(\texttt{FACCAO}{=}1 \mid \texttt{PORTE}, \texttt{FRONT})$, vai de 0,013 (pequeno, sem fronteira) a 0,861 (grande, com fronteira). A conjunta das 6 variáveis ($3 \cdot 2 \cdot 2 \cdot 3 \cdot 2 \cdot 3 = 216$ células) exige 215 parâmetros; a rede, 19: $2 + 1 + 6 + 4 + 2 + 4$. Economia de 196 parâmetros (91%).

Inferência por enumeração. Implementamos $P(X \mid e) = \alpha \sum_y \prod_i P(x_i \mid pais(X_i))$ do zero e comparamos com a `VariableElimination` do `pgmpy` em 7 consultas (15 probabilidades): a maior diferença é $1{,}1 \times 10^{-16}$. Exemplos: $P(F \mid \text{grande}) = 0{,}79$; $P(F \mid \text{pequeno}) =$

UF	n	facção	P média	AUC
AC	22	1,00	0,47	–
RR	15	0,93	0,47	0,64
PA	144	0,51	0,53	0,78
RO	52	0,50	0,43	0,58
AM	62	0,32	0,32	0,65
AP	16	0,31	0,51	0,85
MT	141	0,30	0,51	0,75
MA	217	0,22	0,21	0,79
TO	139	0,06	0,11	0,94

Tabela 9: Validação deixando um estado de fora.

0,13; um município pequeno de fronteira com os três sintomas no nível mais alto tem $P(F) = 0{,}43$; um grande, sem fronteira e sem sintomas, 0,29.

d-separação. (1) *Garfo*: `TXH`←`FACCAO`→`ESC`; dado `FACCAO`, os sintomas são d-separados. (2) *Colisor*: `PORTE`→`FACCAO`←`FRONT`. Sem observar `FACCAO`, $P(\texttt{FRONT} \mid \text{pequeno}) = P(\texttt{FRONT} \mid \text{grande}) = 0{,}559$: independentes. Observando `FACCAO`=1, o caminho se abre: $P(\texttt{FRONT} \mid \text{pequeno}, F) = 0{,}955$ contra 0,608 para grande. É o *explaining away*: uma facção num município pequeno é mais bem "explicada" pela rota do tráfico do que pelo tamanho. Nos dados, porte e fronteira têm correlação 0,21; a independência marginal suposta pelo DAG é uma aproximação.

A rede como classificador. Em 5 dobras, AUC = 0,81 (acurácia 76,1%, balanceada 0,713). As probabilidades passadas à Etapa 6 são *fora da dobra*: cada município recebe a $P(F)$ de uma rede treinada sem ele, para que a validação seguinte não seja otimista.

Rede × árvore. Com as mesmas dobras, a decisão da ID3 (Etapa 1) e a da rede ($P \geq 0{,}5$) concordam em 83% dos municípios: quando ambas dizem "facção", 76% têm; quando ambas dizem "sem", 15%. Nos 36 que só a árvore marca, 75% têm facção: ela usa a UF inteira, e a rede só `FRONT`. As duas ordenam igualmente bem (AUC 0,81). `LATRO`, 3º no ganho, como quarto sintoma quase não muda a AUC de 2024 (0,814) e piora a da entrada em 2025 (0,750 contra 0,764); fica fora.

Deixando um estado de fora. A AUC geral cai pouco (0,80), mas a tabela por estado mostra o que a média esconde (Tabela 9). A rede ordena bem os municípios em TO, AP, MA e PA, mas erra o *nível* onde a facção é quase universal: no Acre e em Roraima a P média prevista é cerca de 0,47, porque `FRONT` só distingue MA e TO dos demais. Serve para ordenar municípios num estado conhecido, não para estimar o nível num estado novo.

Sensibilidade ao rótulo. Sem os 45 municípios que "saíram" da lista em 2025, a AUC sobe para 0,83; a rede já os via com probabilidade intermediária (0,40, contra 0,58 dos que têm facção nas duas edições e 0,23 dos sem facção), o que é coerente com erro de registro ou

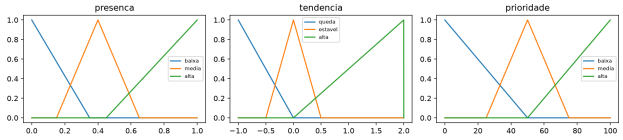


Figura 6: Funções de pertinência.

mudança de método. Com o rótulo "facção em 2024 ou 2025", a AUC é 0,82. As conclusões não dependem do ruído do rótulo.

8 Etapa 6 — Lógica fuzzy e integração

Variáveis linguísticas. O sistema Mamdani (`scikit-fuzzy`) tem duas entradas: *presença* = média da $P(F)$ da rede (Etapa 5) e da do NB + EM (Etapa 4), ambas fora da dobra (baixa, média, alta, centradas em torno da taxa-base de 32%) e *tendência* = variação relativa dos homicídios de 2020–21 para 2022–23 (queda, estável, alta). A saída é a *prioridade* de monitoramento, de 0 a 100 (Figura 6). Todas as funções de pertinência são triangulares, que em sistemas Mamdani para nível de criminalidade classificaram melhor do que as trapezoidais [19].

Regras.

1. SE presença alta E (tendência alta OU estável) ENTÃO prioridade alta.
2. SE presença alta E tendência em queda ENTÃO prioridade média (possível domínio consolidado).
3. SE presença média E tendência alta ENTÃO prioridade alta (possível expansão).
4. SE presença média E (estável OU queda) ENTÃO prioridade média.
5. SE presença baixa ENTÃO prioridade baixa.

A regra 2 traduz um padrão descrito na literatura: onde uma facção já domina sozinha, a violência pode cair ("paz do domínio"). A defuzzificação é pelo centroide; classificamos a saída em baixa (< 40), média (40–60) e alta (≥ 60).

Conferência com 2024 e 2025. A Tabela 10 confere a decisão com o rótulo de 2024 e com as entradas de 2025. A proporção com facção cresce de 12% para 64% da prioridade baixa para a alta, e a de disputa, de 1,6% para 28,4%. Entre os 549 sem facção em 2024, a taxa de entrada em 2025 vai de 14% na baixa para 45% na alta. É uma validação fora do tempo: nenhum dado de 2025 foi usado.

A média com o NB + EM melhora a ordenação de 2024 (o NB usa a UF inteira), mas não a da entrada em 2025: a prevalência do estado diz onde a facção está, não para onde vai.

Fuzzy × limiar rígido. O limiar presença $\geq 0{,}5$ divide os municípios em 242 "alta" e 566 "baixa". Ele também separa bem (entrada em 2025: 47% contra 20%), mas joga numa só classe os 471 sem facção que ficaram abaixo do limiar. O fuzzy cria uma faixa intermediária

Prioridade	Munic.	Facção 2024	Disputa	Entrada 2025*
Baixa	426	12,4%	1,6%	13,9%
Média	146	37,0%	7,5%	42,4%
Alta	236	64,4%	28,4%	45,2%

Tabela 10: *Entre os municípios sem facção em 2024. AUC (facção 2024 / entrada 2025): rede 0,809 / 0,764; NB + EM 0,840 / 0,728; presença (média) 0,836 / 0,753; prioridade fuzzy 0,815 / 0,749.

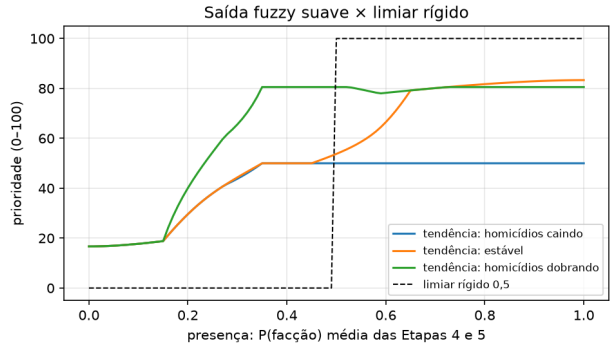


Figura 7: Prioridade fuzzy em função de $P(F)$ para três tendências, contra o limiar rígido.

de 146 municípios que já concentra 42% de entradas, e a saída é contínua perto da fronteira de decisão (Figura 7): um município com $P = 0{,}49$ e outro com 0,51 recebem prioridades próximas, não opostas. Isso importa aqui porque o rótulo é ruidoso ("sem registro" não é ausência certa) e a fronteira entre as classes é ambígua: são exatamente os casos em que o fuzzy supera o limiar rígido. A tendência também desloca a prioridade, o que um limiar sobre P não faz.

A violência de 2024 antecipa a chegada? Com o VDE de 2024, testamos duas hipóteses com uma regressão logística em 5 dobras, só entre os sem facção em 2024. (i) Trocar a janela 2021–23 por 2022–24 não melhora (AUC 0,754 nas duas). (ii) Municípios cujos homicídios saltaram em 2024 entraram mais (31% contra 21%), mas o salto de 2023 tem o mesmo efeito (32% contra 21%). O salto é sinal de município violento, não da chegada da facção. Estudos de caso, como o de Iranduba (AM), em que os homicídios subiram 318% em 2021 após a criação de uma facção [15], não aparecem como padrão na escala dos 808 municípios.

Interpretabilidade. Cada regra é uma frase que um analista de inteligência entende e pode contestar, e cada entrada tem origem rastreável: a presença vem da rede e do Naive Bayes (ambos tabelas de frequência) e a tendência vem direto do VDE.

9 Experimentos com outras variáveis

O enunciado limita a árvore a 4–6 atributos e a rede a 4–6 nós, e o pipeline já usa 6. Testamos então 15 variáveis candidatas *trocando* um nó da rede (em geral `ESC`), com as mesmas validações (`experimentos_variaveis.ipynb`); a Tabela 11 resume.

Variável na rede	2024	Estado fora	Entrada 2025
Atual	0,810	0,800	**0,764**
Faixa de fronteira no lugar de `FRONT`	**0,837**	**0,811**	0,708
Vizinho com facção (malha IBGE)	0,819	0,800	0,742
Urbanização (Censo 2022)	0,819	0,788	0,731
Hierarquia urbana (REGIC)	0,807	0,787	0,751
Latrocínio, feminicídio, mandados	0,81–0,82	0,80–0,81	0,73–0,76
Suicídio, trânsito (placebos)	0,813–0,815	0,80	0,752
Garimpo IBAMA / INPE	0,813 / 0,809	0,79–0,80	0,747
Desmatamento (DETER)	0,808	0,796	0,733

Tabela 11: AUC da rede com cada variável candidata (probabilidades fora da dobra).

Fronteira por município. Trocar `FRONT` por estado pela faixa de fronteira do IBGE melhora o diagnóstico (AUC 0,84) e corrige boa parte do erro de nível: com o estado de fora, a P média prevista sobe para 0,68 no Acre e 0,70 em Roraima. Mas a previsão da entrada em 2025 cai para 0,71: nos estados de fronteira, a expansão foi tão frequente no interior (38%) quanto na faixa (36%), e a variável municipal rebaixa justamente o interior do Pará, do Mato Grosso e do Amazonas. Como o objetivo final é antecipar a expansão, mantivemos `FRONT` por estado.

As demais. Nenhuma muda a AUC de 2024 em mais de 0,01, e todas pioram a entrada em 2025. Os placebos (suicídio, trânsito) rendem tanto quanto as variáveis de violência: os sintomas da rede carregam sobretudo o tamanho e a urbanização do município. Vizinhos, urbanização e hierarquia urbana repetem o que porte e estado já dizem. Numa logística só para a entrada em 2025, nenhuma variável eleva a AUC (0,779) além do desvio entre dobras (0,05). O garimpo dobra a taxa de entrada, mas atinge só cerca de 40 dos 549 municípios, pouco para mudar a AUC do conjunto.

10 Discussão

A Tabela 12 compara os resultados com as faixas de referência do enunciado. Ficamos dentro ou acima nas Etapas 1 e 2 (regressão). Ficamos abaixo na logística e no NB + EM. A razão é o próprio problema: a taxa-base é 32%, os atributos públicos (violência e população) só capturam parte do fenômeno e o rótulo só tem positivos confiáveis (Seção 12). A AUC de 0,81 mostra que os modelos ordenam bem os municípios; o que limita a acurácia é a sobreposição real entre municípios violentos sem facção e facções que dominam sem violência. O EM converge em 5 iterações (contagem) ou 38 (taxa), fora da faixa de 15–30, porque a tolerância é relativa (10^{-4}); a curva cresce monotonicamente, como esperado.

O fio condutor do pipeline é a passagem da certeza à incerteza graduada. A árvore produz regras legíveis, mas a monotonicidade mostra que elas quebram com um fato novo. A probabilidade substitui "é/não é" por graus de crença; o EM mostra que a variável oculta deixa rastro nos dados; a rede organiza essas crenças com poucos

Métrica	Esperado	Obtido
Árvore: treino sem poda	85–92%	87,4%
Árvore: teste 5-fold	72–80%	78,6%
Profundidade ótima	3–5	3–5
R^2 simples	0,55–0,65	0,672
R^2 multivariada	0,70–0,80	0,763
R^2 Ridge	0,72–0,82	0,762
Logística	78–85%	75,9%
Naive Bayes puro	72–78%	77,2%
Naive Bayes + EM	80–86%	77,7%
Enumeração = `pgmpy`	idêntico	dif. 10^{-16}

Tabela 12: Resultados obtidos × faixas de referência do enunciado.

parâmetros e permite raciocinar nos dois sentidos; e o fuzzy devolve uma decisão legível, agora sem fronteiras rígidas.

11 Comunicação

Houve comunicação com a equipe 5 sobre o trabalho:

Equipe 5 — Segurança Pública: Nosso projeto utiliza indicadores oficiais de segurança pública para aplicar técnicas de Inteligência Artificial, incluindo árvores de decisão, regressão, inferência probabilística, estimação estatística, redes Bayesianas e lógica fuzzy. Buscamos identificar situações de elevado volume de ocorrências que possam demandar maior atenção da gestão pública.

Equipe 1 — Facções Criminosas na Amazônia Legal: Nosso estudo investiga a presença e a expansão de facções criminosas nos municípios da Amazônia Legal. Utilizamos rótulos provenientes das Cartografias, 3ª e 4ª edições, e atributos extraídos do Banco VDE do SINESP/MJSP, abrangendo o período de 2020 a 2024. Também integramos informações populacionais do IBGE e indicadores externos do IBAMA, INPE e IBGE.

Equipe 5 — Segurança Pública: Uma diferença importante entre os projetos está na unidade de análise. Trabalhamos com indicadores agregados por unidade federativa e período, enquanto vocês utilizam informações municipais. A granularidade municipal pode permitir análises territoriais mais específicas, embora exija cuidados adicionais com a qualidade e a integração dos dados.

Equipe 1 — Facções Criminosas na Amazônia Legal: Exatamente. Nossa metodologia utiliza códigos municipais para integrar diferentes fontes. Além dos registros de violência, consideramos variáveis territoriais e ambientais que podem contribuir para investigar associações com a presença de facções. Essas associações, entretanto, não devem ser interpretadas automaticamente como relações causais.

Equipe 5 — Segurança Pública: Essa abordagem oferece uma perspectiva complementar à nossa. As técnicas probabilísticas e de classificação utilizadas em nosso trabalho poderiam, em estudos futuros, ser aplicadas a indicadores municipais para investigar padrões territoriais, desde que fossem realizados novos treinamentos e validações.

Equipe 1 — Facções Criminosas na Amazônia Legal: Da mesma forma, a utilização de redes Bayesianas e lógica fuzzy poderia contribuir para representar incertezas e produzir classificações interpretáveis. Entretanto, seria necessário avaliar a qualidade dos rótulos e os riscos de generalização indevida dos resultados.

Equipe 5 — Segurança Pública: Concluímos que os projetos são complementares: enquanto nossa pesquisa analisa indicadores agregados de segurança pública para apoiar o monitoramento, o estudo de vocês investiga padrões municipais relacionados à presença e à expansão de facções criminosas. A integração dessas perspectivas poderia fundamentar pesquisas futuras sobre análise territorial e apoio à decisão pública.

Síntese: A comparação evidencia a importância da granularidade territorial, da integração de bases oficiais, da interpretação probabilística e da validação dos modelos. Também demonstra que indicadores de violência e presença de organizações criminosas representam fenômenos distintos, que não devem ser tratados como equivalentes.

12 Conclusão e limitações

O porte do município e o estado explicam a maior parte da presença registrada de facção na Amazônia Legal; a violência refina essa estimativa. A probabilidade calculada com dados até 2023 antecipa parte da expansão observada em 2025 (AUC 0,76), mas a violência indica onde a facção tende a estar, não quando ela chega. O garimpo, medido pelo IBAMA e pelo INPE, é a pista mais clara de para onde ela vai: dobra a taxa de entrada em 2025. Das 15 variáveis de outras bases que testamos, nenhuma melhorou os modelos de forma consistente; o limite parece estar no rótulo, não na falta de atributos.

Limitações. (1) "Sem registro" no Cartografias significa facção não identificada pelos pesquisadores, não ausência certa; por isso falamos em facção registrada. Formalmente, é aprendizado com positivos e não rotulados [18]: se os registros fossem uma amostra aleatória dos municípios com facção, a probabilidade estimada diferiria da verdadeira por um fator constante. A ordenação (e a AUC) se preservaria, mas o nível e a acurácia ficariam subestimados. (2) Parte das mudanças entre a 3ª e a 4ª edição vem da melhoria do método; 45 municípios "saíram" da lista. (3) O relatório tem pequenas divergências entre as tabelas por estado e o quadro-resumo (AP, PA, TO); definimos "disputa" pelo número de facções listadas. (4) O Maranhão entra inteiro (217 municípios), mas só 181 pertencem à Amazônia Legal. (5) `FRONT` é definido por estado; a versão por município corrige o erro de nível em AC e RR, mas piora a previsão de 2025 (Seção 9). (6) Não há estimativa do IBGE para 2023; as taxas usam o Censo 2022.

Ética. A saída é uma prioridade estatística para orientar monitoramento, não uma acusação. Modelos treinados com registros de fiscalização tendem a prever onde há fiscalização, e não só onde há crime [20]; isso vale para

o Cartografias e para os autos do IBAMA. Municípios com prioridade alta e sem registro (por exemplo, Oriximiná, PA, com $P = 0{,}92$) são candidatos a verificação, não municípios "dominados": como nos "falsos positivos" de [17], podem ser municípios com facção ainda não registrada. Rotular publicamente uma localidade pode gerar estigma e afetar investimento e turismo; por isso a lista de candidatos fica restrita ao notebook.

Referências

[1] S. Russell e P. Norvig. *Artificial Intelligence: A Modern Approach*, 4. ed. Pearson, 2020 (caps. 18–20).

[2] L. A. Zadeh. Fuzzy sets. *Information and Control*, 8(3):338–353, 1965.

[3] E. Hüllermeier. Fuzzy machine learning and data mining. *WIREs DMKD*, 1(4):269–283, 2011.

[4] Instituto Mãe Crioula e Fórum Brasileiro de Segurança Pública. *Cartografias da Violência na Amazônia*, 3. ed., 2024.

[5] Instituto Mãe Crioula e Fórum Brasileiro de Segurança Pública. *Cartografias da Violência na Amazônia*, 4. ed., 2025.

[6] Ministério da Justiça e Segurança Pública. Banco VDE (SINESP), 2020–2024. `https://dadosabertos.mj.gov.br`. Acesso em out. 2026.

[7] IBGE. Censo Demográfico 2022, Estimativas da População, Municípios da Faixa de Fronteira 2024, Malha Municipal e REGIC 2018. `https://www.ibge.gov.br`. Acesso em nov. 2026.

[8] IBAMA. Dados abertos: autos de infração e termos de destruição. `https://dadosabertos.ibama.gov.br`. Acesso em nov. 2026.

[9] INPE. DETER Amazônia, TerraBrasilis. `https://terrabrasilis.dpi.inpe.br`. Acesso em nov. 2026.

[10] Í. B. L. Siqueira e L. F. S. Paiva. "No Norte tem Comando": as maneiras de fazer o crime, a guerra e o domínio das prisões do Amazonas. *Revista Brasileira de Sociologia*, 7(17):125–154, 2019. DOI 10.20336/rbs.486.

[11] A. C. O. Couto. Fronteiras e estrutura espacial do narcotráfico na Amazônia. *Boletim Gaúcho de Geografia*, 47(1), 2020.

[12] A. C. O. Couto. Relações transfronteiriças do narcotráfico na Amazônia: dos crimes conexos aos desafios da segurança regional. *Boletim de Análise Político-Institucional (Ipea)*, 36, 2024. DOI 10.38116/bapi36art5.

[13] R. P. Chagas. O "narcogarimpo" na Terra Indígena Yanomami. *Boletim de Análise Político-Institucional (Ipea)*, 36, 2024. DOI 10.38116/bapi36art7.

[14] R. Pereira-Chagas. Narcogarimpo: las afinidades electivas entre los frentes de minería ilegal y la expansión del narcotráfico en la Amazonía brasileña. *URVIO*, 38:32–48, 2024. DOI 10.17141/urvio.38.2024.6144.

[15] P. V. A. Sales, L. C. Sena, F. C. Bezerra Neto e C. M. A. Mello. O impacto da criação da facção Revolucionários do Amazonas (RDA) nos índices de violência letal em Iranduba-AM no período de 2017 a 2024. *Revista Geopolítica Transfronteiriça*, 9(4):1–15, 2025.

[16] J. Ribeiro, L. Meneses, D. Costa, W. Miranda e R. Alves. Prediction of Homicides in Urban Centers: A Machine Learning Approach. *IntelliSys*, 2021. arXiv:2008.06979.

[17] G. M. Campedelli, G. Daniele e M. Le Moglie. Mafia, Politics and Machine Predictions. CEPR Discussion Paper 19322, 2024.

[18] C. Elkan e K. Noto. Learning Classifiers from Only Positive and Unlabeled Data. *KDD*, p. 213–220, 2008.

[19] N. M. Mohamad Noor e S. H. Ab Hamid. Comparison of Triangular and Trapezoidal Membership Functions for Improving Decision Making in Crime Prevention. *Frontiers in Artificial Intelligence and Applications*, 261, 2014. DOI 10.3233/978-1-61499-399-5-69.

[20] K. Lum e W. Isaac. To Predict and Serve? *Significance*, 13(5):14–19, 2016.

A Uso de assistente de IA

Usamos um assistente de IA (Claude, via Claude Code) como apoio à implementação do código e à análise estatística, e para revisar parte do texto. As decisões do trabalho (a pergunta de pesquisa, a escolha dos atributos, o protocolo de validação e a interpretação dos resultados) foram da equipe. Todo o código foi lido, executado e conferido por nós, e os números do relatório vêm da execução dos notebooks com `seed = 42`.

Preparação dos dados. O assistente ajudou a escrever os scripts que montam a base municipal do VDE (2020–2024) e a juntam à população do IBGE pelo código do município, a extrair do PDF do Cartografias 2025 os quadros de facções por estado (`extrair_cartografias_2025.py`) e a agregar por município as bases externas usadas na Seção 9 (`montar_bases_externas.py`).

Implementação dos algoritmos. Com o assistente, implementamos do zero o ID3, a regressão com gradiente descendente, a regressão logística, o Naive Bayes, o EM para mistura de gaussianas e a inferência por enumeração na rede bayesiana. Cada implementação foi comparada com a biblioteca correspondente (scikit-learn e `pgmpy`); a coincidência dos resultados, por exemplo a diferença máxima de 10^{-16} na enumeração, serviu de verificação do código.

Análise estatística. O assistente auxiliou a tornar a validação mais rigorosa: tercis calculados apenas no treino de cada dobra, probabilidades da rede obtidas fora da dobra, validação deixando um estado de fora e validação fora do tempo com a 4ª edição do Cartografias. Também ajudou a organizar os experimentos com as 15 variáveis candidatas (`experimentos_variaveis.ipynb`), os testes de hipótese e as tabelas comparativas do relatório.

Revisão bibliográfica e entrega. O assistente sugeriu artigos relacionados ao tema; títulos, autores e trechos citados foram conferidos por nós nos PDFs. Ele também ajudou a preparar o relatório em LaTeX, o README e os notebooks para a entrega.

B Reprodução

`pip install -r requirements.txt`; `python utils.py`; executar `etapa1.ipynb` a `etapa6.ipynb` em ordem (a Etapa 5 grava `dados/probabilidades_bayesianas.csv`, lido pela Etapa 6). Repositório: `https://github.com/RomarioAndrade/seguranca-publica-ml-fuzzy`.