# Do Simbólico à Incerteza: inferindo a presença e a expansão de facções criminosas nos municípios da Amazônia Legal

Equipe 1 — P3 Segurança Pública

Gabriel Menezes Rodrigues, Luiz Felipe Gonzaga do Carmo, Joshua Tadeu Bastos Pereira,
Romário Roberto de Pádua Andrade, Ruan Pablo Nascimento de Aragão, Fernando Teles dos Reis

Fundamentos de Inteligência Artificial — Prof. Edjard Mota — IComp/UFAM, 2026/2

Novembro de 2026

## Resumo

A presença de facções criminosas não aparece em nenhuma base oficial: é uma variável oculta. Combinamos as estatísticas de violência do SINESP VDE (2020–2024) e a população do IBGE para inferi-la nos 808 municípios dos estados da Amazônia Legal, usando como referência o *Cartografias da Violência na Amazônia* de 2024. Percorremos as seis etapas do pipeline: árvore de decisão, modelos lineares, probabilidade, Naive Bayes com EM, rede bayesiana e lógica fuzzy. A rede bayesiana diagnóstica atinge AUC de 0,81 (0,80 testando num estado que não viu). Sem usar nenhum dado de 2025, a probabilidade calculada antecipa quais municípios passaram a ter facção segundo a edição de 2025 (AUC 0,76): na prioridade fuzzy baixa, 13% entraram; na alta, 44%. A violência indica *onde* a facção tende a estar, mas não *quando* ela chega.

A resposta final é uma **prioridade de monitoramento** por município, produzida por um sistema fuzzy que recebe a probabilidade calculada pela rede bayesiana. A prioridade não é uma acusação: indica onde a inteligência policial teria mais chance de encontrar atuação de facção.

## 1 Introdução

Nas duas últimas décadas, facções criminosas nascidas no Sudeste (PCC e Comando Vermelho) e grupos regionais se espalharam pela Amazônia, atraídos pelas rotas fluviais e terrestres da cocaína produzida na Bolívia, no Peru e na Colômbia e pelo sistema prisional, onde se organizam [10, 4]. O *Cartografias da Violência na Amazônia*, do Fórum Brasileiro de Segurança Pública com o Instituto Mãe Crioula, mapeia município a município quais facções atuam na região: na 3ª edição (dados de 2024) havia registro em 259 dos 808 municípios dos nove estados; na 4ª edição (2025), em 344.

Esse mapeamento depende de trabalho de campo e de fontes policiais e não é atualizado continuamente. As estatísticas de violência, por outro lado, são publicadas todo ano pelo Ministério da Justiça. A pergunta deste trabalho é:

> *O município da Amazônia Legal tem presença de facção criminosa (2024), dado o seu porte e o padrão de violência registrado entre 2021 e 2023? E o modelo antecipa quais municípios passaram a ter facção em 2025?*

## 2 Dados e protocolo de validação

**Fontes.** (i) *Rótulos*: Cartografias, 3ª edição [4] (Tabelas 13–21, presença em 2024) e 4ª edição [5] (quadros por estado, extraídos do PDF com `extrair_cartografias_2025.py`). (ii) *Atributos*: Banco VDE do SINESP/MJSP [6], 2020–2024, por município (homicídio doloso, tentativa, morte a esclarecer, latrocínio, mandados). (iii) *População*: IBGE, Censo 2022 e estimativas [7], unida pelo código do município. Os 5.570 municípios do VDE casaram com o IBGE; os 808 dos 9 estados casaram com o Cartografias. (iv) *Bases externas*, usadas na análise do garimpo e nos experimentos (Seção 9): autos de infração e termos de destruição do IBAMA [8], alertas do DETER/INPE [9], faixa de fronteira, malha municipal e REGIC do IBGE [7], todos de 2021–23 e agregados por município (`montar_bases_externas.py`). Dos arquivos do IBAMA, que identificam os autuados, guardamos só contagens por município.

**Atributos.** Para a árvore, o Naive Bayes e a rede, usamos atributos discretos e interpretáveis (Tabela 1). As taxas são médias anuais de 2021–23 por 100 mil habitantes (Censo 2022).

| Variável | Definição |
|---|---|
| `PORTE` | pequeno (<10 mil), médio (10–50 mil), grande (50 mil+) |
| `TXH` | taxa de homicídio 2021–23, em tercis |
| `TXT` | taxa de tentativas de homicídio 2021–23, em tercis |
| `ESC` | teve morte a esclarecer em 2021–23 |
| `LATRO` | teve latrocínio em 2021–23 |
| `UF/FRONT` | estado / estado faz fronteira com outro país |
| `ALVO` | facção registrada em 2024 (32,1%) |

**Tabela 1:** Atributos e alvo.

**Validação.** Sempre com `seed = 42`: (a) validação cruzada estratificada de 5 dobras, recalculando os tercis de `TXH` e `TXT` com os cortes do treino de cada dobra, para o teste não influenciar a discretização; (b) *deixando um estado de fora* (treina com 8, testa no 9º); (c) *fora do tempo*: entre os 549 municípios sem facção em 2024, quais passaram a ter em 2025, rótulo que nenhum modelo viu. Como as classes são desbalanceadas ("sempre não" acerta 67,9%), reportamos também acurácia balanceada e AUC.

# 3 Etapa 1 — Árvore de decisão

**Entropia e ganho (cálculo manual).** Na raiz, 259 dos 808 municípios têm facção: $H = -\frac{259}{808}\log_2\frac{259}{808} - \frac{549}{808}\log_2\frac{549}{808} = 0{,}905$ bits. Para `PORTE`, os filhos são pequeno (27/267 com facção, $H = 0{,}473$), médio (145/435, $H = 0{,}918$) e grande (87/106, $H = 0{,}678$). A entropia ponderada é $(267 \cdot 0{,}473 + 435 \cdot 0{,}918 + 106 \cdot 0{,}678)/808 = 0{,}740$, e o ganho é $0{,}905 - 0{,}740 = 0{,}165$, o maior entre os seis atributos (Tabela 2).

| | PORTE | UF | LATRO | ESC | TXH | TXT |
|---|---|---|---|---|---|---|
| Ganho | **0,165** | 0,151 | 0,070 | 0,030 | 0,027 | 0,017 |

**Tabela 2:** Ganho de informação na raiz (nível 1).

No **nível 2**, em todos os três ramos de porte o melhor atributo é `UF`: ganho de 0,167 entre os pequenos ($H = 0{,}473$), 0,133 entre os médios ($H = 0{,}918$) e 0,044 entre os grandes ($H = 0{,}678$). No **nível 3**, os atributos de violência finalmente aparecem: nos médios do Mato Grosso ($n = 61$, $H = 0{,}929$) o melhor é `TXT` (ganho 0,135); nos médios de Rondônia ($n = 23$, $H = 0{,}999$) e do Amazonas ($n = 48$, $H = 0{,}696$), `TXH` (0,164 e 0,107); nos médios do Maranhão ($n = 153$) e do Pará ($n = 90$), `LATRO` (0,040 e 0,035). A árvore diz, portanto, que o tamanho do município e o estado explicam a maior parte da presença de facção; a violência refina a decisão dentro de cada estado.

**Implementação e validação.** Implementamos o Learn-Decision-Tree (ID3) do zero e comparamos com o `DecisionTreeClassifier` (critério entropia) em 5 dobras (Tabela 3). As duas implementações sem poda dão o mesmo resultado (0,749 e 0,745). A poda por profundidade reduz o sobreajuste: o treino cai de 87% para 82% e o teste sobe para 78,6%. A Figura 2 mostra a curva de profundidade.

| Modelo | Treino | Teste | Bal. |
|---|---|---|---|
| ID3 própria, sem poda | 0,874 | 0,749 | 0,687 |
| ID3 própria, prof. 3 | 0,824 | **0,786** | **0,708** |
| sklearn, sem poda | 0,875 | 0,745 | 0,683 |
| sklearn, prof. 4 | 0,799 | 0,782 | 0,679 |

**Tabela 3:** Validação cruzada 5-fold (tercis calculados no treino de cada dobra).

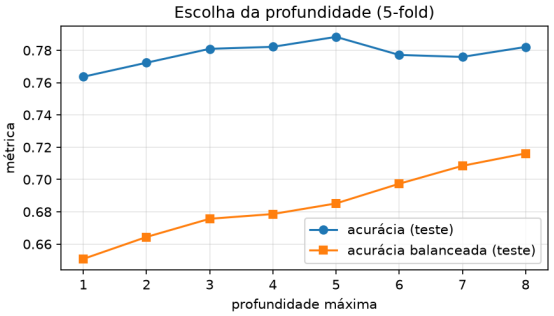



**Figura 2:** Acurácia de teste por profundidade máxima.

**Monotonicidade.** A regra mais simples sugerida pelos dados é $\forall x\,(Pequeno(x) \rightarrow \neg Facção(x))$. Ela cobre 267 municípios e acerta 89,9%. Mas, ao acrescentarmos um único fato novo, "o município fica no Acre" ou "em Roraima", a conclusão se inverte: todos os pequenos desses estados têm facção (3 de 3 e 2 de 2), e em Rondônia 9 de 22. São estados de fronteira, na rota da cocaína, onde a facção chega até às cidades pequenas. Na lógica clássica, o raciocínio é monotônico: se a regra foi aceita como axioma, nenhum fato novo a derruba, e a base passaria a ser inconsistente. No mundo real, a informação nova invalida a conclusão anterior. Esse é o limite das regras rígidas que motiva as etapas seguintes, em que as conclusões são graus de crença revisáveis.

# 4 Etapa 2 — Modelos lineares

**Regressão.** Como alvo contínuo usamos $y = \log(1 + \text{homicídios em 2023})$. Os 16 atributos são log(população) e as contagens de 2020–2022 (em $\log(1+x)$). Divisão 80/20. A regressão univariada por fórmula fechada sobre os homicídios de 2022 dá $\hat{y} = 0{,}282 + 0{,}812\,x$ ($R^2 = 0{,}672$). A multivariada com gradiente descendente do zero (atributos padronizados, $\alpha = 0{,}05$, 5.000 iterações) chega a $R^2 = 0{,}763$. Como os 16 atributos são muito correlacionados (o mesmo evento em três anos seguidos), aplicamos Ridge: o $\lambda$ escolhido por validação cruzada é 0,084, com $R^2 = 0{,}762$ (Figura 3). À medida que $\lambda$ cresce, os coeficientes encolhem e deixam de oscilar entre anos correlacionados.

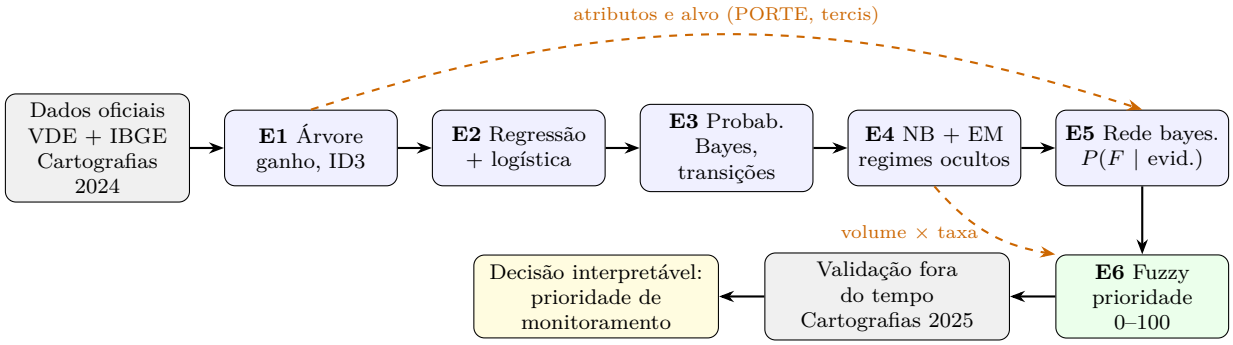



**Figura 1:** Pipeline integrado. As setas tracejadas indicam reutilização: os atributos e a discretização definidos na Etapa 1 alimentam a rede, e o EM mostra que o volume de violência importa, o que orienta a escolha das entradas do sistema fuzzy.

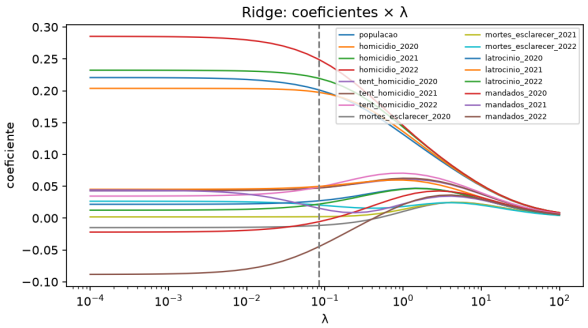



**Figura 3:** Coeficientes do Ridge em função de $\lambda$.

**Logística.** Para o problema da Etapa 1, implementamos a regressão logística (sigmoide + gradiente, com pesos de classe balanceados). Acurácia de 75,9% e balanceada de 0,737, idênticas ao `LogisticRegression`. Todos os modelos próprios coincidem com o scikit-learn até a terceira casa (Tabela 4).

| Modelo | $R^2$ | Acurácia (bal.) |
|---|---|---|
| Simples (hom. 2022 → 2023) | 0,672 | – |
| Multivariada (GD, 16 atributos) | 0,763 | – |
| Ridge ($\lambda = 0{,}084$) | 0,762 | – |
| Logística (facção) | – | 0,759 (0,737) |

**Tabela 4:** Resultados no teste (20%). O scikit-learn dá os mesmos valores.

# 5 Etapa 3 — Probabilidade

Cada município é um "mundo". Definimos $F$ = tem facção em 2024; $V$ = taxa de homicídio no tercil mais alto; $E$ = teve morte a esclarecer. A conjunta de $F$ e $V$ está na Tabela 5.

| | $F=0$ | $F=1$ | $P(V)$ |
|---|---|---|---|
| $V=0$ | 0,4876 | 0,1795 | 0,6671 |
| $V=1$ | 0,1918 | 0,1411 | 0,3329 |
| $P(F)$ | 0,6795 | 0,3205 | 1,0000 |

**Tabela 5:** Distribuição conjunta (4 eventos atômicos).

**Bayes: causal × diagnóstico.** O sentido *causal* é $P(V \mid F)$: a facção provoca disputas e execuções. Nos dados, $P(V{=}1 \mid F{=}1) = 0{,}440$. O analista, porém, observa o efeito e quer a causa oculta, o sentido *diagnóstico*:

$$P(F \mid V) = \frac{P(V \mid F)\,P(F)}{P(V)} = \frac{0{,}440 \times 0{,}3205}{0{,}3329} = 0{,}424,$$

contra $P(F \mid \neg V) = 0{,}269$: a taxa alta multiplica a chance por 1,6. A conferência direta na tabela dá o mesmo valor.

**Regra da cadeia.** $P(F,V,E) = P(F)\,P(V \mid F)\,P(E \mid F,V)$ reproduz exatamente as 8 probabilidades conjuntas (soma 1). **Independência condicional.** Testamos se $V$ e $E$ são independentes dado $F$: para $F=0$, $P(V,E \mid F) = 0{,}204$ contra o produto 0,167 ($\chi^2 = 14{,}5$, $p < 10^{-3}$); para $F=1$, 0,386 contra 0,350 ($p = 0{,}006$). A hipótese do Naive Bayes é violada: os dois sintomas compartilham uma causa que não está no modelo (o volume de violência).

**Por que a LPO não diz "42% de chance".** A fórmula $\forall x\,(\mathit{ViolênciaAlta}(x) \rightarrow \mathit{Facção}(x))$ é falsa, porque há municípios violentos sem facção; a sua negação também não serve. A lógica de primeira ordem só atribui verdadeiro ou falso; para dizer "em 42% dos casos" é preciso uma medida de crença, que é a probabilidade.

**Transições 2024 → 2025.** Com a 4ª edição, a distribuição conjunta dos regimes nos dois anos (Tabela 6) mostra a dinâmica. Dos 549 municípios sem registro em 2024, 129 (23,5%) passaram a ter facção em 2025, e a chance cresce com o porte: 13,8% nos pequenos, 30,7% nos médios e 36,8% nos grandes. Por Bayes, $P(\text{entrada} \mid \text{grande}) = 0{,}054 \times 0{,}235/0{,}035 = 0{,}368$. Também há 45 "saídas", o que sugere que parte da mudança vem do método, como o próprio relatório admite.

| 2024 \ 2025 | sem reg. | uma | disputa | total |
|---|---|---|---|---|
| sem registro | 420 | 111 | 18 | 549 |
| uma facção | 32 | 126 | 16 | 174 |
| disputa | 13 | 18 | 54 | 85 |

**Tabela 6:** Regimes de facção em 2024 e 2025 (municípios).

**Garimpo e a entrada em 2025.** O Cartografias aponta o garimpo ilegal como uma das economias exploradas pelas facções na região. Medimos o garimpo em 2021–23 por duas fontes independentes: auto de infração do IBAMA por garimpo ou mineração ilegal

(71 municípios) e alerta do DETER/INPE da classe mineração (76). Entre os 549 sem facção em 2024 (Tabela 7), os que tinham garimpo tiveram o dobro de entradas em 2025 nas duas fontes (teste exato de Fisher, $p = 0{,}001$ e 0,003). Por Bayes, com a fonte IBAMA, $P(\text{entrada} \mid G) = P(G \mid \text{entrada})\,P(\text{entrada})/P(G) = 0{,}147 \times 0{,}235/0{,}077 = 0{,}45$. Já a associação com a facção *existente* em 2024 é fraca: pelo IBAMA, dentro do mesmo porte, não há diferença (médios: 37% contra 33%). O garimpo sinaliza *para onde* a facção vai, o que a violência não capta (Seção 8). Cuidados: autuação também reflete onde houve fiscalização, e o DETER inclui mineração legal.

| Entrada em 2025 | IBAMA | INPE |
|---|---|---|
| Com garimpo | 45,2% | 44,7% |
| Sem garimpo | 21,7% | 21,9% |
| Médios com garimpo | 55,6% ($n = 27$) | 60,0% ($n = 25$) |
| Médios sem garimpo | 28,1% | 27,9% |

**Tabela 7:** Entrada de facção em 2025 entre os municípios sem facção em 2024, segundo o garimpo em 2021–23.

# 6 Etapa 4 — MLE, MAP, Naive Bayes e EM

**MLE e MAP.** Para $\theta = P(\text{facção})$ por estado, $\hat{\theta}_{MLE} = k/n$ e, com prior Beta(2,2), $\hat{\theta}_{MAP} = (k+1)/(n+2)$. Onde há poucos municípios, o MLE é extremo: no Acre ($k = n = 22$), $\hat{\theta}_{MLE} = 1$, o que daria probabilidade zero a um município sem facção; o MAP dá 0,958. Em Roraima, 0,933 contra 0,882. Nos estados grandes (PA, MA, MT) os dois coincidem até a segunda casa: o prior só pesa quando há pouca evidência.

**Naive Bayes do zero.** Com suavização de Laplace e os seis atributos da Etapa 1, acurácia de 77,2% e balanceada de 0,737 em 5 dobras, igual ao `CategoricalNB`.

**EM com variável oculta.** O Cartografias classifica cada município em "sem registro", "uma facção (domínio)" ou "disputa". Supomos que esse regime $Z$ é oculto e tentamos recuperá-lo só a partir de $x = \log(1 + \text{homicídios 2021–23})$, com uma mistura de 3 gaussianas ajustada pelo EM (`em.py`). A log-verossimilhança cresce monotonicamente e estabiliza em 5 iterações (Figura 4). O EM nunca vê o rótulo, mas os grupos acompanham o Cartografias (Tabela 8): no grupo menos violento, 1,7% estão em disputa; no mais violento, 29%.

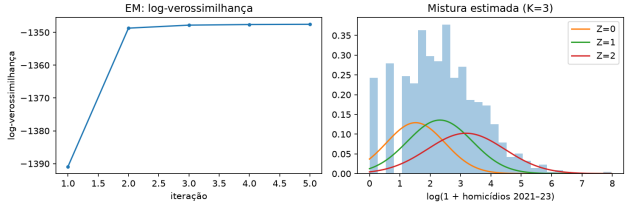



**Figura 4:** EM: log-verossimilhança por iteração e mistura estimada.

| Grupo | $\theta$ | hom. típicos | sem reg. | uma | disputa |
|---|---|---|---|---|---|
| $Z = 0$ | 0,31 | 3,6 | 0,887 | 0,096 | 0,017 |
| $Z = 1$ | 0,36 | 9,2 | 0,724 | 0,219 | 0,057 |
| $Z = 2$ | 0,33 | 23,1 | 0,342 | 0,370 | 0,288 |

**Tabela 8:** Grupos do EM e a composição segundo o Cartografias (linhas somam 1).

Com a *taxa* por 100 mil no lugar da contagem, a correspondência é mais fraca (o grupo mais violento tem 15% em disputa), e o EM leva 38 iterações. A facção está ligada ao *volume* de violência, que acompanha o tamanho do mercado, e não só à intensidade relativa. Com a taxa, uma componente tenta colapsar sobre os municípios sem nenhum homicídio; um piso de variância ($\sigma^2 \geq 0{,}05$) evita a singularidade.

**NB puro × NB + EM.** Trocando os tercis de `TXH` pelo grupo $Z$ (ajustado só no treino de cada dobra), o Naive Bayes passa de 77,2% para 77,7% (balanceada de 0,737 para 0,745). O ganho é pequeno: $Z$ traz o volume de violência, mas boa parte dessa informação já estava em `PORTE`.

# 7 Etapa 5 — Rede bayesiana

**Estrutura.** O DAG (Figura 5) tem 6 nós. `PORTE`→`FACCAO`: cidades maiores concentram mercado consumidor, portos, rodovias e presídios. `FRONT`→`FACCAO`: estados de fronteira estão na rota da cocaína. `FACCAO`→{`TXH`, `ESC`, `TXT`}: disputas e execuções elevam homicídios, tentativas e mortes sem causa esclarecida. A rede é usada no sentido diagnóstico: observamos porte, estado e sintomas e inferimos $P(\texttt{FACCAO} \mid \text{evidências})$.

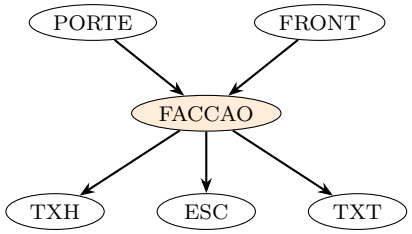



**Figura 5:** DAG: FACCAO é colisor de PORTE e FRONT e causa comum dos três sintomas.

**CPTs e economia.** As CPTs são estimadas por máxima verossimilhança. A tabela central, $P(\texttt{FACCAO}{=}1 \mid \texttt{PORTE}, \texttt{FRONT})$, vai de 0,013 (pequeno, sem fronteira) a 0,861 (grande, com fronteira). A conjunta das 6 variáveis ($3 \cdot 2 \cdot 2 \cdot 3 \cdot 2 \cdot 3 = 216$ células) exige 215 parâmetros; a rede, 19: $2 + 1 + 6 + 4 + 2 + 4$. Economia de 196 parâmetros (91%).

**Inferência por enumeração.** Implementamos $P(X \mid e) = \alpha \sum_y \prod_i P(x_i \mid pais(X_i))$ do zero e comparamos com a `VariableElimination` do `pgmpy` em 7 consultas (15 probabilidades): a maior diferença é $1{,}1 \times 10^{-16}$. Exemplos: $P(F \mid \text{grande}) = 0{,}79$; $P(F \mid \text{pequeno}) = 0{,}13$; um município pequeno de fronteira com os três sintomas no nível mais alto tem

$P(F) = 0{,}43$; um grande, sem fronteira e sem sintomas, 0,29.

**d-separação.** (1) *Garfo*: `TXH`←`FACCAO`→`ESC`; dado `FACCAO`, os sintomas são d-separados. (2) *Colisor*: `PORTE`→`FACCAO`←`FRONT`. Sem observar `FACCAO`, $P(\texttt{FRONT} \mid \text{pequeno}) = P(\texttt{FRONT} \mid \text{grande}) = 0{,}559$: independentes. Observando `FACCAO`= 1, o caminho se abre: $P(\texttt{FRONT} \mid \text{pequeno}, F) = 0{,}955$ contra 0,608 para grande. É o *explaining away*: uma facção num município pequeno é mais bem "explicada" pela rota do tráfico do que pelo tamanho. Nos dados, porte e fronteira têm correlação 0,21; a independência marginal suposta pelo DAG é uma aproximação.

**A rede como classificador.** Em 5 dobras, AUC = 0,81 (acurácia 76,1%, balanceada 0,713). As probabilidades passadas à Etapa 6 são *fora da dobra*: cada município recebe a $P(F)$ de uma rede treinada sem ele, para que a validação seguinte não seja otimista.

**Deixando um estado de fora.** A AUC geral cai pouco (0,80), mas a tabela por estado mostra o que a média esconde (Tabela 9). A rede ordena bem os municípios em TO, AP, MA e PA, mas erra o *nível* onde a facção é quase universal: no Acre e em Roraima a $P$ média prevista é cerca de 0,47, porque `FRONT` só distingue MA e TO dos demais. Serve para ordenar municípios num estado conhecido, não para estimar o nível num estado novo.

| UF | $n$ | facção | $P$ média | AUC |
|---|---|---|---|---|
| AC | 22 | 1,00 | 0,47 | – |
| RR | 15 | 0,93 | 0,47 | 0,64 |
| PA | 144 | 0,51 | 0,53 | 0,78 |
| RO | 52 | 0,50 | 0,43 | 0,58 |
| AM | 62 | 0,32 | 0,32 | 0,65 |
| AP | 16 | 0,31 | 0,51 | 0,85 |
| MT | 141 | 0,30 | 0,51 | 0,75 |
| MA | 217 | 0,22 | 0,21 | 0,79 |
| TO | 139 | 0,06 | 0,11 | 0,94 |

**Tabela 9:** Validação deixando um estado de fora.

**Sensibilidade ao rótulo.** Sem os 45 municípios que "saíram" da lista em 2025, a AUC sobe para 0,83; a rede já os via com probabilidade intermediária (0,40, contra 0,58 dos que têm facção nas duas edições e 0,23 dos sem facção), o que é coerente com erro de registro ou mudança de método. Com o rótulo "facção em 2024 ou 2025", a AUC é 0,82. As conclusões não dependem do ruído do rótulo.

# 8 Etapa 6 — Lógica fuzzy e integração

**Variáveis linguísticas.** O sistema Mamdani (`scikit-fuzzy`) tem duas entradas: *presença* = $P(F)$ vinda da rede (baixa, média, alta, centradas em torno da taxa-base de 32%) e *tendência* = variação relativa dos homicídios de 2020–21 para 2022–23 (queda, estável, alta). A saída é a *prioridade* de monitoramento, de 0 a 100 (Figura 6). Todas as funções de pertinência são triangulares.

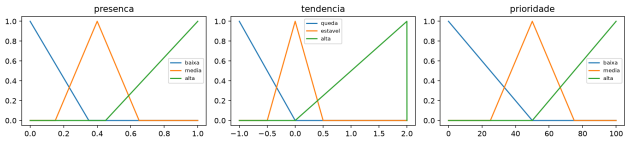



**Figura 6:** Funções de pertinência.

**Regras.**

1. SE presença alta E (tendência alta OU estável) ENTÃO prioridade alta.
2. SE presença alta E tendência em queda ENTÃO prioridade média (possível domínio consolidado).
3. SE presença média E tendência alta ENTÃO prioridade alta (possível expansão).
4. SE presença média E (estável OU queda) ENTÃO prioridade média.
5. SE presença baixa ENTÃO prioridade baixa.

A regra 2 traduz um padrão descrito na literatura: onde uma facção já domina sozinha, a violência pode cair ("paz do domínio"). A defuzzificação é pelo centroide; classificamos a saída em baixa ($< 40$), média (40–60) e alta ($\geq 60$).

**Conferência com 2024 e 2025.** A Tabela 10 confere a decisão com o rótulo de 2024 e com as entradas de 2025. A proporção com facção cresce de 13% para 61% da prioridade baixa para a alta, e a de disputa, de 1,7% para 25,5%. Entre os 549 sem facção em 2024, a taxa de entrada em 2025 vai de 13% na baixa para 44% na alta. É uma validação fora do tempo: nenhum dado de 2025 foi usado.

| Prioridade | Munic. | Facção 2024 | Disputa | Entrada 2025* |
|---|---|---|---|---|
| Baixa | 404 | 12,9% | 1,7% | 13,1% |
| Média | 165 | 37,6% | 10,3% | 40,8% |
| Alta | 239 | 60,7% | 25,5% | 43,6% |

**Tabela 10:** *Entre os municípios sem facção em 2024. AUC para prever a entrada: $P(F)$ bayesiana 0,764; prioridade fuzzy 0,751.

**Fuzzy × limiar rígido.** O limiar $P \geq 0{,}5$ divide os municípios em 234 "alta" e 574 "baixa". Ele também separa bem (entrada em 2025: 54% contra 18%), mas joga numa só classe os 465 que ficaram abaixo do limiar. O fuzzy cria uma faixa intermediária de 165 municípios que já concentra 41% de entradas, e a saída é contínua perto da fronteira de decisão (Figura 7): um município com $P = 0{,}49$ e outro com 0,51 recebem prioridades próximas, não opostas. Isso importa aqui porque o rótulo é ruidoso ("sem registro" não é ausência certa) e a fronteira entre as classes é ambígua: são exatamente os casos em que o fuzzy supera o limiar rígido. A tendência também desloca a prioridade, o que um limiar sobre $P$ não faz.

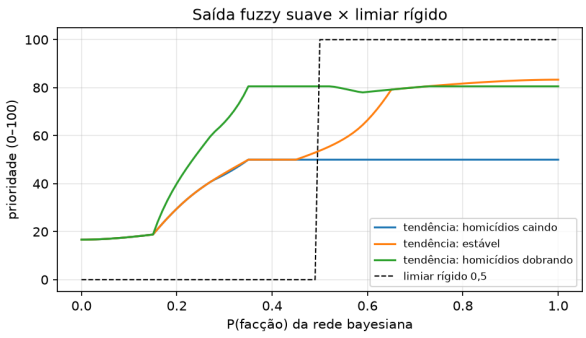



**Figura 7:** Prioridade fuzzy em função de $P(F)$ para três tendências, contra o limiar rígido.

**A violência de 2024 antecipa a chegada?** Com o VDE de 2024, testamos duas hipóteses com uma regressão logística em 5 dobras, só entre os sem facção em 2024. (i) Trocar a janela 2021–23 por 2022–24 não melhora (AUC 0,754 nas duas). (ii) Municípios cujos homicídios saltaram em 2024 entraram mais (31% contra 21%), mas o salto de 2023 tem o mesmo efeito (32% contra 21%). O salto é sinal de município violento, não da chegada da facção. Relatos de caso, como o de Iranduba (AM), em que os homicídios dispararam após a criação de uma facção, não aparecem como padrão na escala dos 808 municípios.

**Interpretabilidade.** Cada regra é uma frase que um analista de inteligência entende e pode contestar, e cada entrada tem origem rastreável: a presença vem da rede (cujas CPTs são tabelas de frequência) e a tendência vem direto do VDE.

# 9 Experimentos com outras variáveis

O enunciado limita a árvore a 4–6 atributos e a rede a 4–6 nós, e o pipeline já usa 6. Testamos então 15 variáveis candidatas *trocando* um nó da rede (em geral `ESC`), com as mesmas validações (`experimentos_variaveis.ipynb`); a Tabela 11 resume.

| Variável na rede | 2024 | Estado fora | Entrada 2025 |
|---|---|---|---|
| Atual | 0,810 | 0,800 | **0,764** |
| Faixa de fronteira no lugar de `FRONT` | **0,837** | **0,811** | 0,708 |
| Vizinho com facção (malha IBGE) | 0,819 | 0,800 | 0,742 |
| Urbanização (Censo 2022) | 0,819 | 0,788 | 0,731 |
| Hierarquia urbana (REGIC) | 0,807 | 0,787 | 0,751 |
| Latrocínio, feminicídio, mandados | 0,81–0,82 | 0,80–0,81 | 0,73–0,76 |
| Suicídio, trânsito (placebos) | 0,813–0,815 | 0,80 | 0,752 |
| Garimpo IBAMA / INPE | 0,813 / 0,809 | 0,79–0,80 | 0,747 |
| Desmatamento (DETER) | 0,808 | 0,796 | 0,733 |

**Tabela 11:** AUC da rede com cada variável candidata (probabilidades fora da dobra).

**Fronteira por município.** Trocar `FRONT` por estado pela faixa de fronteira do IBGE melhora o diagnóstico (AUC 0,84) e corrige boa parte do erro de nível: com o estado de fora, a $P$ média prevista sobe para 0,68 no Acre e 0,70 em Roraima. Mas a previsão da entrada em 2025 cai para 0,71: nos estados de fronteira, a expansão foi tão frequente no interior (38%) quanto na faixa (36%), e a variável municipal rebaixa justamente o interior do Pará, do Mato Grosso e do Amazonas. Como o objetivo final é antecipar a expansão, mantivemos `FRONT` por estado.

**As demais.** Nenhuma muda a AUC de 2024 em mais de 0,01, e todas pioram a entrada em 2025. Os placebos (suicídio, trânsito) rendem tanto quanto as variáveis de violência: os sintomas da rede carregam sobretudo o tamanho e a urbanização do município. Vizinhos, urbanização e hierarquia urbana repetem o que porte e estado já dizem. Numa logística só para a entrada em 2025, nenhuma variável eleva a AUC (0,779) além do desvio entre dobras (0,05). O garimpo dobra a taxa de entrada, mas atinge só cerca de 40 dos 549 municípios, pouco para mudar a AUC do conjunto.

# 10 Discussão

A Tabela 12 compara os resultados com as faixas de referência do enunciado. Ficamos dentro ou acima nas Etapas 1 e 2 (regressão). Ficamos abaixo na logística e no NB + EM. A razão é o próprio problema: a taxa-base é 32%, os atributos públicos (violência e população) só capturam parte do fenômeno e o rótulo é ruidoso. A AUC de 0,81 mostra que os modelos ordenam bem os municípios; o que limita a acurácia é a sobreposição real entre municípios violentos sem facção e facções que dominam sem violência. O EM converge em 5 iterações (contagem) ou 38 (taxa), fora da faixa de 15–30, porque a tolerância é relativa ($10^{-4}$); a curva cresce monotonicamente, como esperado.

| Métrica | Esperado | Obtido |
|---|---|---|
| Árvore: treino sem poda | 85–92% | 87,4% |
| Árvore: teste 5-fold | 72–80% | 78,6% |
| Profundidade ótima | 3–5 | 3–5 |
| $R^2$ simples | 0,55–0,65 | 0,672 |
| $R^2$ multivariada | 0,70–0,80 | 0,763 |
| $R^2$ Ridge | 0,72–0,82 | 0,762 |
| Logística | 78–85% | 75,9% |
| Naive Bayes puro | 72–78% | 77,2% |
| Naive Bayes + EM | 80–86% | 77,7% |
| Enumeração = pgmpy | idêntico | dif. $10^{-16}$ |

**Tabela 12:** Resultados obtidos × faixas de referência do enunciado.

O fio condutor do pipeline é a passagem da certeza à incerteza graduada. A árvore produz regras legíveis, mas a monotonicidade mostra que elas quebram com um fato novo. A probabilidade substitui "é/não é" por graus de crença; o EM mostra que a variável oculta deixa rastro nos dados; a rede organiza essas crenças com poucos parâmetros e permite raciocinar nos dois sentidos; e o fuzzy devolve uma decisão legível, agora sem fronteiras rígidas.

# 11 Conclusão e limitações

O porte do município e o estado explicam a maior parte da presença registrada de facção na Amazônia Legal; a

violência refina essa estimativa. A probabilidade calculada com dados até 2023 antecipa parte da expansão observada em 2025 (AUC 0,76), mas a violência indica *onde* a facção tende a estar, não *quando* ela chega. O garimpo, medido pelo IBAMA e pelo INPE, é a pista mais clara de *para onde* ela vai: dobra a taxa de entrada em 2025. Das 15 variáveis de outras bases que testamos, nenhuma melhorou os modelos de forma consistente; o limite parece estar no rótulo, não na falta de atributos.

**Limitações.** (1) "Sem registro" no Cartografias significa facção não identificada pelos pesquisadores, não ausência certa; por isso falamos em facção *registrada*. (2) Parte das mudanças entre a 3ª e a 4ª edição vem da melhoria do método; 45 municípios "saíram" da lista. (3) O relatório tem pequenas divergências entre as tabelas por estado e o quadro-resumo (AP, PA, TO); definimos "disputa" pelo número de facções listadas. (4) O Maranhão entra inteiro (217 municípios), mas só 181 pertencem à Amazônia Legal. (5) `FRONT` é definido por estado; a versão por município corrige o erro de nível em AC e RR, mas piora a previsão de 2025 (Seção 9). (6) Não há estimativa do IBGE para 2023; as taxas usam o Censo 2022.

**Ética.** A saída é uma prioridade estatística para orientar monitoramento, não uma acusação. Municípios com prioridade alta e sem registro (por exemplo, Oriximiná, PA, com $P = 0{,}92$) são candidatos a verificação, não municípios "dominados". Rotular publicamente uma localidade pode gerar estigma e afetar investimento e turismo; por isso a lista de candidatos fica restrita ao notebook.

# Referências


[1] S. Russell e P. Norvig. *Artificial Intelligence: A Modern Approach*, 4. ed. Pearson, 2020 (caps. 18–20).

[2] L. A. Zadeh. Fuzzy sets. *Information and Control*, 8(3):338–353, 1965.

[3] E. Hüllermeier. Fuzzy machine learning and data mining. *WIREs DMKD*, 1(4):269–283, 2011.

[4] Instituto Mãe Crioula e Fórum Brasileiro de Segurança Pública. *Cartografias da Violência na Amazônia*, 3. ed., 2024.

[5] Instituto Mãe Crioula e Fórum Brasileiro de Segurança Pública. *Cartografias da Violência na Amazônia*, 4. ed., 2025.

[6] Ministério da Justiça e Segurança Pública. Banco VDE (SINESP), 2020–2024. `https://dadosabertos.mj.gov.br`. Acesso em out. 2026.

[7] IBGE. Censo Demográfico 2022, Estimativas da População, Municípios da Faixa de Fronteira 2024, Malha Municipal e REGIC 2018. `https://www.ibge.gov.br`. Acesso em nov. 2026.

[8] IBAMA. Dados abertos: autos de infração e termos de destruição. `https://dadosabertos.ibama.gov.br`. Acesso em nov. 2026.

[9] INPE. DETER Amazônia, TerraBrasilis. `https://terrabrasilis.dpi.inpe.br`. Acesso em nov. 2026.

[10] I. Siqueira e L. Paiva. "No Norte, tem Comando": as facções criminosas na Amazônia. *Revista Brasileira de Sociologia*, 7(17), 2019.

[11] J. Ribeiro et al. Prediction of Homicides in Urban Centers. arXiv:2008.06979.


# A Uso de assistente de IA

Usamos um assistente de IA (Claude, via Claude Code) para gerar e revisar parte do código e do texto. Todo o código foi lido, executado e conferido pela equipe; os números do relatório vêm da execução dos notebooks com `seed = 42`. Principais pedidos feitos ao assistente:

1. "Monte a base municipal do VDE 2020–2024 para os estados da Amazônia Legal e junte com a população do IBGE pelo código do município."
2. "Extraia do PDF do Cartografias 2025 os quadros de facções por município de cada estado."
3. "O município da Amazônia Legal tem presença de facção criminosa (2024), dado o seu porte e o padrão de violência registrado entre 2021 e 2023? E o modelo antecipa quais municípios passaram a ter facção em 2025? Implemente as 6 etapas do enunciado."
4. "Implemente do zero o ID3, o gradiente descendente, a logística, o Naive Bayes, o EM e a inferência por enumeração, e compare com scikit-learn e pgmpy."
5. "Torne a validação mais rigorosa: probabilidades fora da dobra, tercis calculados no treino e validação deixando um estado de fora."
6. "Teste outras variáveis do IBGE e de bases abertas do governo (fronteira por município, garimpo e desmatamento, IBAMA), sem passar do limite de 6 atributos."
7. "Prepare o trabalho para entrega conforme o enunciado (relatório LaTeX de 6–8 páginas, README e notebooks)."

# B Reprodução

`pip install -r requirements.txt`; `python utils.py`; executar `etapa1.ipynb` a `etapa6.ipynb` em ordem (a Etapa 5 grava `dados/probabilidades_bayesianas.csv`, lido pela Etapa 6). Repositório: `https://github.com/RomarioAndrade/seguranca-publica-ml-fuzzy`.