Do Simbólico à Incerteza: inferindo a presença e a expansão de facções criminosas nos municípios da Amazônia Legal

Equipe 1 — P3 Segurança Pública

Gabriel Menezes Rodrigues, Luiz Felipe Gonzaga do Carmo, Joshua Tadeu Bastos Pereira,
Romário Roberto de Pádua Andrade, Ruan Pablo Nascimento de Aragão, Fernando Teles dos Reis

Fundamentos de Inteligência Artificial — Prof. Edjard Mota — IComp/UFAM, 2026/2

Novembro de 2026

Resumo

A presença de facções criminosas não é registrada de forma direta em uma única base oficial, por isso precisa ser estimada a partir de outras informações. Neste trabalho, usamos dados de violência do SINESP VDE (2020–2024) e dados populacionais do IBGE para analisar 808 municípios da Amazônia Legal. Como referência para identificar a presença de facções, utilizamos o *Cartografias da Violência na Amazônia*, edição de 2024. O estudo foi organizado em seis etapas, envolvendo árvore de decisão, modelos lineares, probabilidade, Naive Bayes com EM, rede bayesiana e lógica fuzzy. A rede bayesiana obteve AUC de 0,81, chegando a 0,80 no teste em um estado que não participou do treinamento. Mesmo sem utilizar dados de 2025 no treinamento, o modelo conseguiu antecipar parte dos municípios que passaram a ter registro de facção na edição daquele ano (AUC de 0,76). Entre os municípios classificados com prioridade fuzzy baixa, 13% tiveram entrada; entre os de prioridade alta, esse percentual foi de 44%. Os resultados indicam que os dados de violência ajudam a estimar *onde* há maior possibilidade de atuação de facções, mas não permitem determinar exatamente *quando* elas chegam.

1 Introdução

Nas últimas duas décadas, facções que surgiram no Sudeste, como o PCC e o Comando Vermelho, além de grupos regionais, ampliaram sua atuação na Amazônia. Entre os fatores associados a essa expansão estão as rotas fluviais e terrestres utilizadas no transporte de cocaína produzida na Bolívia, no Peru e na Colômbia [11], além da organização desses grupos dentro do sistema prisional [10]. A literatura também descreve um processo de interiorização das facções na região, associado inclusive ao garimpo ilegal [12, 13]. O estudo *Cartografias da Violência na Amazônia*, elaborado pelo Fórum Brasileiro de Segurança Pública em parceria com o Instituto Mãe Crioula, apresenta um levantamento da atuação desses grupos nos municípios da região. Na terceira edição, com dados de 2024, foram identificados registros em 259 dos 808 municípios dos nove estados. Na quarta edição, referente a 2025, esse número passou para 344.

Esse tipo de mapeamento depende de pesquisas de campo e de informações fornecidas por fontes policiais. Por esse motivo, sua atualização não ocorre de forma contínua. Já as estatísticas de violência são divulgadas anualmente pelo Ministério da Justiça. Trabalhos próximos utilizam aprendizado de máquina para prever homicídios em Belém a partir de boletins de ocorrência [16] e para prever a infiltração mafiosa em municípios italianos, com validação fora do tempo [17]. Neste último estudo, parte dos "falsos positivos" se parece com municípios infiltrados que ainda não haviam sido detectados, ponto que retomamos na Seção 11. A partir dessa diferença entre as fontes, definimos a seguinte questão de pesquisa:

> *O município da Amazônia Legal tem presença de facção criminosa (2024), dado o seu porte e o padrão de violência registrado entre 2021 e 2023? E o modelo antecipa quais municípios passaram a ter facção em 2025?*

Como resultado, o trabalho gera uma **prioridade de monitoramento** para cada município. Essa classificação é produzida por um sistema fuzzy que utiliza como entrada a probabilidade estimada pela rede bayesiana. É importante destacar que a prioridade não representa uma acusação nem confirma a presença de uma facção. Ela apenas indica os locais que, de acordo com os dados analisados, poderiam merecer uma investigação mais detalhada.

2 Dados e protocolo de validação

Fontes. (i) *Rótulos*: Cartografias, 3ª edição [4] (Tabelas 13–21, presença em 2024) e 4ª edição [5] (quadros por estado, extraídos do PDF com `extrair_cartografias_2025.py`). (ii) *Atributos*: Banco VDE do SINESP/MJSP [6], 2020–2024, por município (homicídio doloso, tentativa, morte a esclarecer, latrocínio, mandados). (iii) *População*: IBGE, Censo 2022 e estimativas [7], unida pelo código do município. Os 5.570 municípios do VDE casaram com o IBGE; os

808 dos 9 estados casaram com o Cartografias. (iv) *Bases externas*, usadas na análise do garimpo e nos experimentos (Seção 9): autos de infração e termos de destruição do IBAMA [8], alertas do DETER/INPE [9], faixa de fronteira, malha municipal e REGIC do IBGE [7], todos de 2021–23 e agregados por município (`montar_bases_externas.py`). Dos arquivos do IBAMA, que identificam os autuados, guardamos só contagens por município.

Atributos. Para a árvore, o Naive Bayes e a rede, usamos atributos discretos e interpretáveis (Tabela 1). As taxas são médias anuais de 2021–23 por 100 mil habitantes (Censo 2022).

Variável	Definição
`PORTE`	pequeno (<10 mil), médio (10–50 mil), grande (50 mil+)
`TXH`	taxa de homicídio 2021–23, em tercis
`TXT`	taxa de tentativas de homicídio 2021–23, em tercis
`ESC`	teve morte a esclarecer em 2021–23
`LATRO`	teve latrocínio em 2021–23
`UF/FRONT`	estado / estado faz fronteira com outro país
`ALVO`	facção registrada em 2024 (32,1%)

Tabela 1: Atributos e alvo.

Validação. Todas as execuções utilizaram `seed = 42`. Foram adotadas três formas de avaliação: (a) validação cruzada estratificada em cinco dobras, com os tercis de `TXH` e `TXT` recalculados a partir dos dados de treinamento de cada dobra, evitando que as informações do teste influenciassem a discretização; (b) avaliação *deixando um estado de fora*, na qual o modelo é treinado com oito estados e testado no nono; e (c) avaliação *fora do tempo*, verificando, entre os 549 municípios sem registro de facção em 2024, quais passaram a apresentar registro em 2025. Esse último rótulo não foi utilizado no treinamento dos modelos. Como as classes são desbalanceadas — um classificador que sempre prevê a classe negativa já alcançaria 67,9% de acurácia —, também apresentamos a acurácia balanceada e a AUC.

3 Etapa 1 — Árvore de decisão

Entropia e ganho (cálculo manual). Na raiz, 259 dos 808 municípios têm facção: $H = -\frac{259}{808}\log_2\frac{259}{808} - \frac{549}{808}\log_2\frac{549}{808} = 0{,}905$ bits. Para `PORTE`, os filhos são pequeno (27/267 com facção, $H = 0{,}473$), médio (145/435, $H = 0{,}918$) e grande (87/106, $H = 0{,}678$). A entropia ponderada é $(267 \cdot 0{,}473 + 435 \cdot 0{,}918 + 106 \cdot 0{,}678)/808 = 0{,}740$, e o ganho é $0{,}905 - 0{,}740 = 0{,}165$, o maior entre os seis atributos (Tabela 2).

	PORTE	UF	LATRO	ESC	TXH	TXT
Ganho	**0,165**	0,151	0,070	0,030	0,027	0,017

Tabela 2: Ganho de informação na raiz (nível 1).

No **nível 2**, em todos os três ramos de porte o melhor atributo é `UF`: ganho de 0,167 entre os pequenos ($H = 0{,}473$), 0,133 entre os médios ($H = 0{,}918$) e 0,044 entre os grandes ($H = 0{,}678$). No **nível 3**, os atributos de violência finalmente aparecem: nos médios do Mato Grosso ($n = 61$, $H = 0{,}929$) o melhor é `TXT` (ganho 0,135); nos médios de Rondônia ($n = 23$, $H = 0{,}999$) e do Amazonas ($n = 48$, $H = 0{,}696$), `TXH` (0,164 e 0,107); nos médios do Maranhão ($n = 153$) e do Pará ($n = 90$), `LATRO` (0,040 e 0,035). A árvore diz, portanto, que o tamanho do município e o estado explicam a maior parte da presença de facção; a violência refina a decisão dentro de cada estado.

Implementação e validação. Implementamos o Learn-Decision-Tree (ID3) do zero e comparamos com o `DecisionTreeClassifier` (critério entropia) em 5 dobras (Tabela 3). As duas implementações sem poda dão o mesmo resultado (0,749 e 0,745). A poda por profundidade reduz o sobreajuste: o treino cai de 87% para 82% e o teste sobe para 78,6%. A Figura 2 mostra a curva de profundidade.

Modelo	Treino	Teste	Bal.
ID3 própria, sem poda	0,874	0,749	0,687
ID3 própria, prof. 3	0,824	**0,786**	**0,708**
sklearn, sem poda	0,875	0,745	0,683
sklearn, prof. 4	0,799	0,782	0,679

Tabela 3: Validação cruzada 5-fold (tercis calculados no treino de cada dobra).

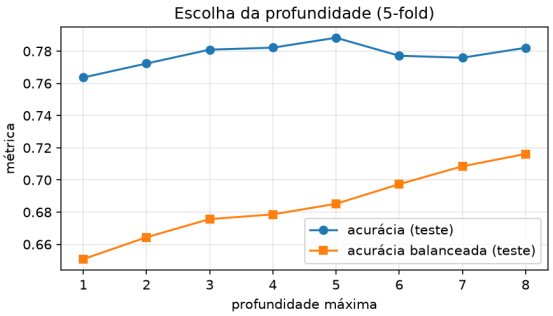


Figura 2: Acurácia de teste por profundidade máxima.

Monotonicidade. A regra mais simples que podemos extrair dos dados é $\forall x\,(Pequeno(x) \rightarrow \neg Facção(x))$. Ela abrange 267 municípios e apresenta 89,9% de acerto. No entanto, quando acrescentamos a informação de que o município está localizado no Acre ou em Roraima, o resultado muda: todos os municípios pequenos desses estados possuem registro de facção na base (3 de 3 no Acre e 2 de 2 em Roraima). Em Rondônia, isso ocorre em 9 dos 22 municípios pequenos. Esses casos mostram que a regra geral não funciona da mesma maneira em todos os estados, especialmente nas áreas de fronteira ligadas às rotas do tráfico. Pela lógica clássica, o raciocínio é monotônico: depois que uma conclusão é derivada, a inclusão de novos fatos não a elimina. Assim, a regra poderia entrar em conflito com as novas informações. Na prática, porém, esses dados

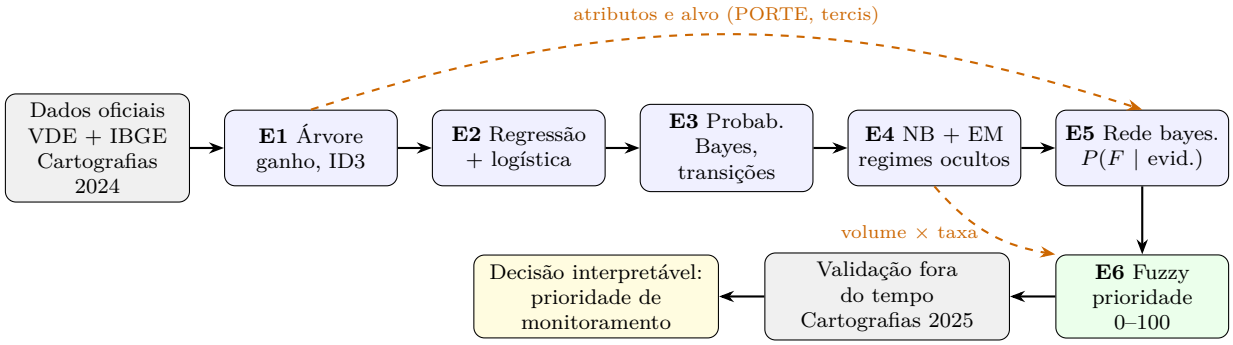


Figura 1: Pipeline integrado. As setas tracejadas indicam reutilização: os atributos e a discretização definidos na Etapa 1 alimentam a rede, e o EM mostra que o volume de violência importa, o que orienta a escolha das entradas do sistema fuzzy.

adicionais mostram que a conclusão inicial precisa ser revista. Essa limitação ajuda a justificar o uso de métodos capazes de representar diferentes graus de incerteza nas etapas seguintes.

4 Etapa 2 — Modelos lineares

Regressão. Como alvo contínuo usamos $y = \log(1 + \text{homicídios em 2023})$. Os 16 atributos são log(população) e as contagens de 2020–2022 (em $\log(1+x)$). Divisão 80/20. A regressão univariada por fórmula fechada sobre os homicídios de 2022 dá $\hat{y} = 0{,}282 + 0{,}812\,x$ ($R^2 = 0{,}672$). A multivariada com gradiente descendente do zero (atributos padronizados, $\alpha = 0{,}05$, 5.000 iterações) chega a $R^2 = 0{,}763$. Como os 16 atributos são muito correlacionados (o mesmo evento em três anos seguidos), aplicamos Ridge: o λ escolhido por validação cruzada é 0,084, com $R^2 = 0{,}762$ (Figura 3). Com o aumento de λ, os coeficientes ficam menores. Esse efeito reduz a variação entre os pesos atribuídos a anos que apresentam informações muito correlacionadas.

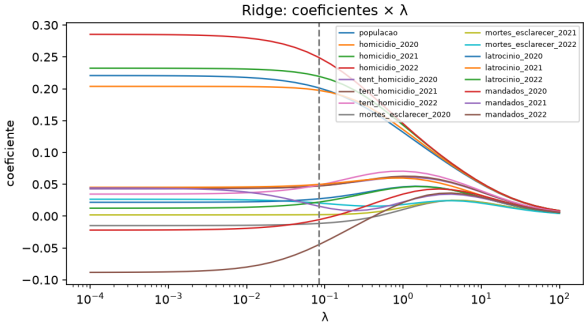


Figura 3: Coeficientes do Ridge em função de λ.

Logística. Para o problema da Etapa 1, implementamos a regressão logística (sigmoide + gradiente, com pesos de classe balanceados). Acurácia de 75,9% e balanceada de 0,737, idênticas ao `LogisticRegression`. Todos os modelos próprios coincidem com o scikit-learn até a terceira casa (Tabela 4).

Modelo	R^2	Acurácia (bal.)
Simples (hom. 2022 → 2023)	0,672	–
Multivariada (GD, 16 atributos)	0,763	–
Ridge ($\lambda = 0{,}084$)	0,762	–
Logística (facção)	–	0,759 (0,737)

Tabela 4: Resultados no teste (20%). O scikit-learn dá os mesmos valores.

5 Etapa 3 — Probabilidade

Cada município é um "mundo". Definimos F = tem facção em 2024; V = taxa de homicídio no tercil mais alto; E = teve morte a esclarecer. A conjunta de F e V está na Tabela 5.

	$F=0$	$F=1$	$P(V)$
$V=0$	0,4876	0,1795	0,6671
$V=1$	0,1918	0,1411	0,3329
$P(F)$	0,6795	0,3205	1,0000

Tabela 5: Distribuição conjunta (4 eventos atômicos).

Bayes: causal × diagnóstico. O sentido *causal* é $P(V \mid F)$: a facção provoca disputas e execuções. Nos dados, $P(V{=}1 \mid F{=}1) = 0{,}440$. No nosso problema, o interesse principal está no sentido inverso: o analista observa os indicadores de violência e tenta estimar a presença da causa que não é observada diretamente. Esse é o sentido *diagnóstico*:

$$P(F \mid V) = \frac{P(V \mid F)\,P(F)}{P(V)} = \frac{0{,}440 \times 0{,}3205}{0{,}3329} = 0{,}424,$$

contra $P(F \mid \neg V) = 0{,}269$: a taxa alta multiplica a chance por 1,6. A conferência direta na tabela dá o mesmo valor.

Regra da cadeia. $P(F, V, E) = P(F)\,P(V \mid F)\,P(E \mid F, V)$ reproduz exatamente as 8 probabilidades conjuntas (soma 1). **Independência condicional.** Testamos se V e E são independentes dado F: para $F = 0$, $P(V, E \mid F) = 0{,}204$ contra o produto 0,167 ($\chi^2 = 14{,}5$, $p < 10^{-3}$); para $F = 1$, 0,386 contra 0,350 ($p = 0{,}006$). Esse resultado indica que a hipótese de independência condicional utilizada pelo Naive Bayes não é plenamente atendida. Uma possível explicação é que

os dois indicadores também estejam relacionados a um fator que não foi representado diretamente no modelo: o volume de violência.

Por que a LPO não diz "42% de chance". A fórmula $\forall x\,(\mathit{ViolênciaAlta}(x) \rightarrow \mathit{Facção}(x))$ é falsa, porque há municípios violentos sem facção; a sua negação também não serve. A lógica de primeira ordem só atribui verdadeiro ou falso; para dizer "em 42% dos casos" é preciso uma medida de crença, que é a probabilidade.

Transições 2024 → 2025. Com a 4ª edição, a distribuição conjunta dos regimes nos dois anos (Tabela 6) mostra a dinâmica. Dos 549 municípios sem registro em 2024, 129 (23,5%) passaram a ter facção em 2025, e a chance cresce com o porte: 13,8% nos pequenos, 30,7% nos médios e 36,8% nos grandes. Por Bayes, $P(\text{entrada} \mid \text{grande}) = 0{,}054 \times 0{,}235/0{,}035 = 0{,}368$. Também há 45 "saídas", o que sugere que parte da mudança vem do método, como o próprio relatório admite.

2024 \ 2025	sem reg.	uma	disputa	total
sem registro	420	111	18	549
uma facção	32	126	16	174
disputa	13	18	54	85

Tabela 6: Regimes de facção em 2024 e 2025 (municípios).

Garimpo e a entrada em 2025. O garimpo ilegal é descrito como uma das economias exploradas pelas facções na região, no que se convencionou chamar de "narcogarimpo" [13, 14]. Medimos o garimpo em 2021–23 por duas fontes independentes: auto de infração do IBAMA por garimpo ou mineração ilegal (71 municípios) e alerta do DETER/INPE da classe mineração (76). Entre os 549 sem facção em 2024 (Tabela 7), os que tinham garimpo tiveram o dobro de entradas em 2025 nas duas fontes (teste exato de Fisher, $p = 0{,}001$ e 0,003). Por Bayes, com a fonte IBAMA, $P(\text{entrada} \mid G) = P(G \mid \text{entrada})\,P(\text{entrada})/P(G) = 0{,}147 \times 0{,}235/0{,}077 = 0{,}45$. Já a associação com a facção *existente* em 2024 é fraca: pelo IBAMA, dentro do mesmo porte, não há diferença (médios: 37% contra 33%). O garimpo sinaliza *para onde* a facção vai, o que a violência não capta (Seção 8). Cuidados: autuação também reflete onde houve fiscalização, e o DETER inclui mineração legal.

Entrada em 2025	IBAMA	INPE
Com garimpo	45,2%	44,7%
Sem garimpo	21,7%	21,9%
Médios com garimpo	55,6% ($n = 27$)	60,0% ($n = 25$)
Médios sem garimpo	28,1%	27,9%

Tabela 7: Entrada de facção em 2025 entre os municípios sem facção em 2024, segundo o garimpo em 2021–23.

6 Etapa 4 — MLE, MAP, Naive Bayes e EM

MLE e MAP. Para $\theta = P(\text{facção})$ por estado, $\hat{\theta}_{MLE} = k/n$ e, com prior Beta(2,2), $\hat{\theta}_{MAP} = (k+1)/(n+2)$. Onde há poucos municípios, o MLE é extremo: no Acre ($k = n = 22$), $\hat{\theta}_{MLE} = 1$, o que daria probabilidade zero a um município sem facção; o MAP dá 0,958. Em Roraima, 0,933 contra 0,882. Nos estados grandes (PA, MA, MT) os dois coincidem até a segunda casa: o prior só pesa quando há pouca evidência.

Naive Bayes do zero. Com suavização de Laplace e os seis atributos da Etapa 1, acurácia de 77,2% e balanceada de 0,737 em 5 dobras, igual ao `CategoricalNB`.

EM com variável oculta. O Cartografias classifica cada município em "sem registro", "uma facção (domínio)" ou "disputa". Supomos que esse regime Z é oculto e tentamos recuperá-lo só a partir de $x = \log(1 + \text{homicídios 2021–23})$, com uma mistura de 3 gaussianas ajustada pelo EM (`em.py`). A log-verossimilhança cresce monotonicamente e estabiliza em 5 iterações (Figura 4). Durante o ajuste, o EM não utiliza os rótulos do Cartografias. Mesmo assim, a distribuição dos municípios entre os três grupos apresenta uma relação com a classificação do relatório (Tabela 8). No grupo com menor número de homicídios, 1,7% dos municípios aparecem em situação de disputa. No grupo com maior número de homicídios, essa proporção chega a 29%.

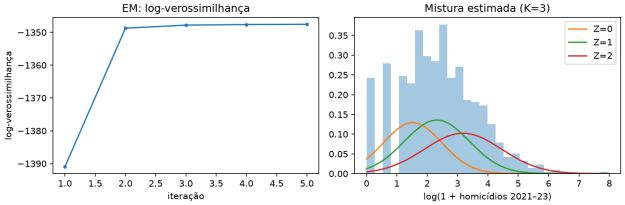


Figura 4: EM: log-verossimilhança por iteração e mistura estimada.

Grupo	θ	hom. típicos	sem reg.	uma	disputa
$Z = 0$	0,31	3,6	0,887	0,096	0,017
$Z = 1$	0,36	9,2	0,724	0,219	0,057
$Z = 2$	0,33	23,1	0,342	0,370	0,288

Tabela 8: Grupos do EM e a composição segundo o Cartografias (linhas somam 1).

Com a *taxa* por 100 mil no lugar da contagem, a correspondência é mais fraca (o grupo mais violento tem 15% em disputa), e o EM leva 38 iterações. Nesse experimento, a contagem de homicídios apresentou uma relação mais clara com os registros de facções do que a taxa por habitante. Isso sugere que o volume de violência, possivelmente relacionado ao tamanho do mercado local, carrega informações que não aparecem quando observamos apenas a intensidade relativa. Com a taxa, uma componente tenta colapsar sobre os municípios sem nenhum homicídio; um piso de variância ($\sigma^2 \geq 0{,}05$) evita a singularidade.

NB puro × NB + EM. Trocando os tercis de `TXH` pelo grupo Z (ajustado só no treino de cada dobra), o Naive Bayes passa de 77,2% para 77,7% (balanceada de 0,737 para 0,745). O ganho é pequeno: Z traz o volume

de violência, mas boa parte dessa informação já estava em PORTE.

7 Etapa 5 — Rede bayesiana

Estrutura. A rede bayesiana é representada por um grafo acíclico direcionado (DAG) com seis nós (Figura 5). No modelo, o porte do município influencia a probabilidade de registro de facção, pois cidades maiores tendem a concentrar mercado consumidor, portos, rodovias e unidades prisionais [10]. A variável FRONT também aponta uma relação com a presença de facções, considerando que as fronteiras e suas cidades funcionam como nós da rede de circulação da cocaína [11]. Por fim, a variável FACCAO está ligada aos três indicadores de violência: TXH, ESC e TXT. A ideia é representar a relação entre a possível presença de facções e os registros de homicídios, tentativas e mortes sem causa esclarecida. Utilizamos a rede no sentido diagnóstico: a partir do porte, do estado e dos indicadores observados, estimamos $P(\texttt{FACCAO} \mid \text{evidências})$.

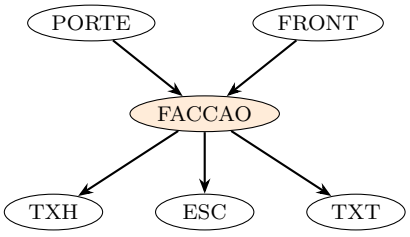


Figura 5: DAG: FACCAO é colisor de PORTE e FRONT e causa comum dos três sintomas.

CPTs e economia. As CPTs são estimadas por máxima verossimilhança. A tabela central, $P(\texttt{FACCAO}{=}1 \mid \texttt{PORTE}, \texttt{FRONT})$, vai de 0,013 (pequeno, sem fronteira) a 0,861 (grande, com fronteira). A conjunta das 6 variáveis ($3 \cdot 2 \cdot 2 \cdot 3 \cdot 2 \cdot 3 = 216$ células) exige 215 parâmetros; a rede, 19: $2 + 1 + 6 + 4 + 2 + 4$. Economia de 196 parâmetros (91%).

Inferência por enumeração. Implementamos $P(X \mid e) = \alpha \sum_y \prod_i P(x_i \mid pais(X_i))$ do zero e comparamos com a `VariableElimination` do `pgmpy` em 7 consultas (15 probabilidades): a maior diferença é $1{,}1 \times 10^{-16}$. Exemplos: $P(F \mid \text{grande}) = 0{,}79$; $P(F \mid \text{pequeno}) = 0{,}13$; um município pequeno de fronteira com os três sintomas no nível mais alto tem $P(F) = 0{,}43$; um grande, sem fronteira e sem sintomas, 0,29.

d-separação. (1) *Garfo*: TXH←FACCAO→ESC; dado FACCAO, os sintomas são d-separados. (2) *Colisor*: PORTE→FACCAO←FRONT. Sem observar FACCAO, $P(\texttt{FRONT} \mid \text{pequeno}) = P(\texttt{FRONT} \mid \text{grande}) = 0{,}559$: independentes. Observando FACCAO= 1, o caminho se abre: $P(\texttt{FRONT} \mid \text{pequeno}, F) = 0{,}955$ contra 0,608 para grande. É o *explaining away*: uma facção num município pequeno é mais bem "explicada" pela rota do tráfico do que pelo tamanho. Nos dados, porte e fronteira têm correlação 0,21; a independência marginal suposta pelo DAG é uma aproximação.

A rede como classificador. Em 5 dobras, AUC = 0,81 (acurácia 76,1%, balanceada 0,713). As probabilidades passadas à Etapa 6 são *fora da dobra*: cada município recebe a $P(F)$ de uma rede treinada sem ele, para que a validação seguinte não seja otimista.

Deixando um estado de fora. A AUC geral cai pouco (0,80), mas a tabela por estado mostra o que a média esconde (Tabela 9). A rede ordena bem os municípios em TO, AP, MA e PA, mas erra o *nível* onde a facção é quase universal: no Acre e em Roraima a P média prevista é cerca de 0,47, porque FRONT só distingue MA e TO dos demais. Serve para ordenar municípios num estado conhecido, não para estimar o nível num estado novo.

UF	n	facção	P média	AUC
AC	22	1,00	0,47	–
RR	15	0,93	0,47	0,64
PA	144	0,51	0,53	0,78
RO	52	0,50	0,43	0,58
AM	62	0,32	0,32	0,65
AP	16	0,31	0,51	0,85
MT	141	0,30	0,51	0,75
MA	217	0,22	0,21	0,79
TO	139	0,06	0,11	0,94

Tabela 9: Validação deixando um estado de fora.

Sensibilidade ao rótulo. Sem os 45 municípios que "saíram" da lista em 2025, a AUC sobe para 0,83; a rede já os via com probabilidade intermediária (0,40, contra 0,58 dos que têm facção nas duas edições e 0,23 dos sem facção), o que é coerente com erro de registro ou mudança de método. Com o rótulo "facção em 2024 ou 2025", a AUC é 0,82. As conclusões não dependem do ruído do rótulo.

8 Etapa 6 — Lógica fuzzy e integração

Variáveis linguísticas. O sistema Mamdani (`scikit-fuzzy`) tem duas entradas: *presença* = $P(F)$ vinda da rede (baixa, média, alta, centradas em torno da taxa-base de 32%) e *tendência* = variação relativa dos homicídios de 2020–21 para 2022–23 (queda, estável, alta). A saída é a *prioridade* de monitoramento, de 0 a 100 (Figura 6). Todas as funções de pertinência são triangulares, que em sistemas Mamdani para nível de criminalidade classificaram melhor do que as trapezoidais [19].

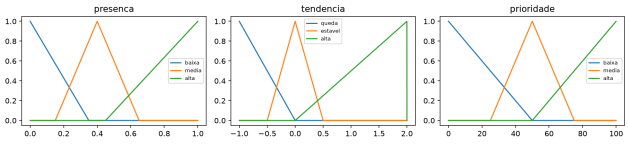


Figura 6: Funções de pertinência.

Regras.

1. SE presença alta E (tendência alta OU estável) ENTÃO prioridade alta.

2. SE presença alta E tendência em queda ENTÃO prioridade média (possível domínio consolidado).
3. SE presença média E tendência alta ENTÃO prioridade alta (possível expansão).
4. SE presença média E (estável OU queda) ENTÃO prioridade média.
5. SE presença baixa ENTÃO prioridade baixa.

A regra 2 traduz um padrão descrito na literatura: onde uma facção já domina sozinha, a violência pode cair ("paz do domínio"). A defuzzificação é pelo centroide; classificamos a saída em baixa (< 40), média (40–60) e alta (≥ 60).

Conferência com 2024 e 2025. A Tabela 10 confere a decisão com o rótulo de 2024 e com as entradas de 2025. A proporção com facção cresce de 13% para 61% da prioridade baixa para a alta, e a de disputa, de 1,7% para 25,5%. Entre os 549 sem facção em 2024, a taxa de entrada em 2025 vai de 13% na baixa para 44% na alta. É uma validação fora do tempo: nenhum dado de 2025 foi usado.

Prioridade	Munic.	Facção 2024	Disputa	Entrada 2025*
Baixa	404	12,9%	1,7%	13,1%
Média	165	37,6%	10,3%	40,8%
Alta	239	60,7%	25,5%	43,6%

Tabela 10: *Entre os municípios sem facção em 2024. AUC para prever a entrada: $P(F)$ bayesiana 0,764; prioridade fuzzy 0,751.

Fuzzy × limiar rígido. O limiar $P \geq 0{,}5$ divide os municípios em 234 "alta" e 574 "baixa". Ele também separa bem (entrada em 2025: 54% contra 18%), mas joga numa só classe os 465 que ficaram abaixo do limiar. O fuzzy cria uma faixa intermediária de 165 municípios que já concentra 41% de entradas, e a saída é contínua perto da fronteira de decisão (Figura 7): um município com $P = 0{,}49$ e outro com 0,51 recebem prioridades próximas, não opostas. Isso importa aqui porque o rótulo é ruidoso ("sem registro" não é ausência certa) e a fronteira entre as classes é ambígua: são exatamente os casos em que o fuzzy supera o limiar rígido. A tendência também desloca a prioridade, o que um limiar sobre P não faz.

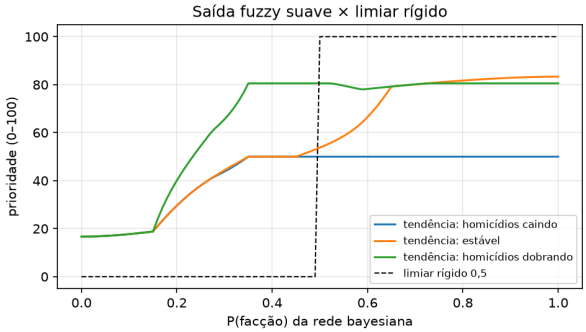


Figura 7: Prioridade fuzzy em função de $P(F)$ para três tendências, contra o limiar rígido.

A violência de 2024 antecipa a chegada? Com o VDE de 2024, testamos duas hipóteses com uma regressão logística em 5 dobras, só entre os sem facção em 2024. (i) Trocar a janela 2021–23 por 2022–24 não melhora (AUC 0,754 nas duas). (ii) Municípios cujos homicídios saltaram em 2024 entraram mais (31% contra 21%), mas o salto de 2023 tem o mesmo efeito (32% contra 21%). O salto é sinal de município violento, não da chegada da facção. Estudos de caso, como o de Iranduba (AM), em que os homicídios subiram 318% em 2021 após a criação de uma facção [15], não aparecem como padrão na escala dos 808 municípios.

Interpretabilidade. Cada regra é uma frase que um analista de inteligência entende e pode contestar, e cada entrada tem origem rastreável: a presença vem da rede (cujas CPTs são tabelas de frequência) e a tendência vem direto do VDE.

9 Experimentos com outras variáveis

O enunciado limita a árvore a 4–6 atributos e a rede a 4–6 nós, e o pipeline já usa 6. Testamos então 15 variáveis candidatas *trocando* um nó da rede (em geral `ESC`), com as mesmas validações (`experimentos_variaveis.ipynb`); a Tabela 11 resume.

Variável na rede	2024	Estado fora	Entrada 2025
Atual	0,810	0,800	**0,764**
Faixa de fronteira no lugar de `FRONT`	**0,837**	**0,811**	0,708
Vizinho com facção (malha IBGE)	0,819	0,800	0,742
Urbanização (Censo 2022)	0,819	0,788	0,731
Hierarquia urbana (REGIC)	0,807	0,787	0,751
Latrocínio, feminicídio, mandados	0,81–0,82	0,80–0,81	0,73–0,76
Suicídio, trânsito (placebos)	0,813–0,815	0,80	0,752
Garimpo IBAMA / INPE	0,813 / 0,809	0,79–0,80	0,747
Desmatamento (DETER)	0,808	0,796	0,733

Tabela 11: AUC da rede com cada variável candidata (probabilidades fora da dobra).

Fronteira por município. Trocar `FRONT` por estado pela faixa de fronteira do IBGE melhora o diagnóstico (AUC 0,84) e corrige boa parte do erro de nível: com o estado de fora, a P média prevista sobe para 0,68 no Acre e 0,70 em Roraima. Mas a previsão da entrada em 2025 cai para 0,71: nos estados de fronteira, a expansão foi tão frequente no interior (38%) quanto na faixa (36%), e a variável municipal rebaixa justamente o interior do Pará, do Mato Grosso e do Amazonas. Como o objetivo final é antecipar a expansão, mantivemos `FRONT` por estado.

As demais. Nenhuma muda a AUC de 2024 em mais de 0,01, e todas pioram a entrada em 2025. Os placebos (suicídio, trânsito) rendem tanto quanto as variáveis de violência: os sintomas da rede carregam sobretudo o tamanho e a urbanização do município. Vizinhos, urbanização e hierarquia urbana repetem o que porte e estado já dizem. Numa logística só para a entrada em 2025, nenhuma variável eleva a AUC (0,779) além do desvio entre dobras (0,05). O garimpo dobra a taxa de entrada, mas atinge só cerca de 40 dos 549 municípios, pouco para mudar a AUC do conjunto.

10 Discussão

A Tabela 12 compara os resultados com as faixas de referência do enunciado. Ficamos dentro ou acima nas Etapas 1 e 2 (regressão). Ficamos abaixo na logística e no NB + EM. A razão é o próprio problema: a taxa-base é 32%, os atributos públicos (violência e população) só capturam parte do fenômeno e o rótulo só tem positivos confiáveis (Seção 11). A AUC de 0,81 mostra que os modelos ordenam bem os municípios; o que limita a acurácia é a sobreposição real entre municípios violentos sem facção e facções que dominam sem violência. O EM converge em 5 iterações (contagem) ou 38 (taxa), fora da faixa de 15–30, porque a tolerância é relativa (10^{-4}); a curva cresce monotonicamente, como esperado.

Métrica	Esperado	Obtido
Árvore: treino sem poda	85–92%	87,4%
Árvore: teste 5-fold	72–80%	78,6%
Profundidade ótima	3–5	3–5
R^2 simples	0,55–0,65	0,672
R^2 multivariada	0,70–0,80	0,763
R^2 Ridge	0,72–0,82	0,762
Logística	78–85%	75,9%
Naive Bayes puro	72–78%	77,2%
Naive Bayes + EM	80–86%	77,7%
Enumeração = pgmpy	idêntico	dif. 10^{-16}

Tabela 12: Resultados obtidos × faixas de referência do enunciado.

Ao longo das seis etapas, o trabalho passa de representações baseadas em respostas rígidas para métodos que permitem expressar diferentes níveis de incerteza. A árvore produz regras legíveis, mas a monotonicidade mostra que elas quebram com um fato novo. A probabilidade substitui "é/não é" por graus de crença; o EM mostra que a variável oculta deixa rastro nos dados; a rede organiza essas crenças com poucos parâmetros e permite raciocinar nos dois sentidos; e o fuzzy devolve uma decisão legível, agora sem fronteiras rígidas.

11 Conclusão e limitações

O porte do município e o estado explicam a maior parte da presença registrada de facção na Amazônia Legal; a violência refina essa estimativa. A probabilidade calculada com dados até 2023 antecipa parte da expansão observada em 2025 (AUC 0,76), mas a violência indica *onde* a facção tende a estar, não *quando* ela chega. O garimpo, medido pelo IBAMA e pelo INPE, é a pista mais clara de *para onde* ela vai: dobra a taxa de entrada em 2025. Das 15 variáveis de outras bases que testamos, nenhuma melhorou os modelos de forma consistente; o limite parece estar no rótulo, não na falta de atributos.

Limitações. (1) "Sem registro" no Cartografias significa facção não identificada pelos pesquisadores, não ausência certa; por isso falamos em facção *registrada*. Formalmente, é aprendizado com positivos e não rotulados [18]: se os registros fossem uma amostra aleatória dos municípios com facção, a probabilidade estimada diferiria da verdadeira por um fator constante. A ordenação (e a AUC) se preservaria, mas o nível e a acurácia ficariam subestimados. (2) Parte das mudanças entre a 3ª e a 4ª edição vem da melhoria do método; 45 municípios "saíram" da lista. (3) O relatório tem pequenas divergências entre as tabelas por estado e o quadro-resumo (AP, PA, TO); definimos "disputa" pelo número de facções listadas. (4) O Maranhão entra inteiro (217 municípios), mas só 181 pertencem à Amazônia Legal. (5) `FRONT` é definido por estado; a versão por município corrige o erro de nível em AC e RR, mas piora a previsão de 2025 (Seção 9). (6) Não há estimativa do IBGE para 2023; as taxas usam o Censo 2022.

Ética. O resultado do sistema deve ser entendido como uma prioridade estatística para orientar o monitoramento, e não como uma acusação. Modelos treinados com registros de fiscalização tendem a prever onde há fiscalização, e não apenas onde há crime [20]; isso vale tanto para o Cartografias quanto para os autos do IBAMA. Um município classificado com prioridade alta, mas sem registro de facção na fonte utilizada — como Oriximiná (PA), com $P = 0{,}92$ — deve ser tratado apenas como um caso que merece verificação. Como nos "falsos positivos" de [17], pode se tratar de um município com facção ainda não registrada, mas essa classificação não permite afirmar que ele esteja dominado por uma organização criminosa. A divulgação pública de resultados desse tipo também pode gerar estigmatização e afetar atividades econômicas, como investimentos e turismo. Por esse motivo, a relação de municípios candidatos à verificação permanece restrita ao notebook.

Referências

[1] S. Russell e P. Norvig. *Artificial Intelligence: A Modern Approach*, 4. ed. Pearson, 2020 (caps. 18–20).

[2] L. A. Zadeh. Fuzzy sets. *Information and Control*, 8(3):338–353, 1965.

[3] E. Hüllermeier. Fuzzy machine learning and data mining. *WIREs DMKD*, 1(4):269–283, 2011.

[4] Instituto Mãe Crioula e Fórum Brasileiro de Segurança Pública. *Cartografias da Violência na Amazônia*, 3. ed., 2024.

[5] Instituto Mãe Crioula e Fórum Brasileiro de Segurança Pública. *Cartografias da Violência na Amazônia*, 4. ed., 2025.

[6] Ministério da Justiça e Segurança Pública. Banco VDE (SINESP), 2020–2024. `https://dadosabertos.mj.gov.br`. Acesso em out. 2026.

[7] IBGE. Censo Demográfico 2022, Estimativas da População, Municípios da Faixa de Fronteira 2024, Malha Municipal e REGIC 2018. `https://www.ibge.gov.br`. Acesso em nov. 2026.

[8] IBAMA. Dados abertos: autos de infração e termos de destruição. `https://dadosabertos.ibama.gov.br`. Acesso em nov. 2026.

[9] INPE. DETER Amazônia, TerraBrasilis. `https://terrabrasilis.dpi.inpe.br`. Acesso em nov. 2026.

[10] Í. B. L. Siqueira e L. F. S. Paiva. "No Norte tem Comando": as maneiras de fazer o crime, a guerra e o domínio das prisões do Amazonas. *Revista Brasileira de Sociologia*, 7(17):125–154, 2019. DOI 10.20336/rbs.486.

[11] A. C. O. Couto. Fronteiras e estrutura espacial do narcotráfico na Amazônia. *Boletim Gaúcho de Geografia*, 47(1), 2020.

[12] A. C. O. Couto. Relações transfronteiriças do narcotráfico na Amazônia: dos crimes conexos aos desafios da segurança regional. *Boletim de Análise Político-Institucional* (Ipea), 36, 2024. DOI 10.38116/bapi36art5.

[13] R. P. Chagas. O "narcogarimpo" na Terra Indígena Yanomami. *Boletim de Análise Político-Institucional* (Ipea), 36, 2024. DOI 10.38116/bapi36art7.

[14] R. Pereira-Chagas. Narcogarimpo: las afinidades electivas entre los frentes de minería ilegal y la expansión del narcotráfico en la Amazonía brasileña. *URVIO*, 38:32–48, 2024. DOI 10.17141/urvio.38.2024.6144.

[15] P. V. A. Sales, L. C. Sena, F. C. Bezerra Neto e C. M. A. Mello. O impacto da criação da facção Revolucionários do Amazonas (RDA) nos índices de violência letal em Iranduba-AM no período de 2017 a 2024. *Revista Geopolítica Transfronteiriça*, 9(4):1–15, 2025.

[16] J. Ribeiro, L. Meneses, D. Costa, W. Miranda e R. Alves. Prediction of Homicides in Urban Centers: A Machine Learning Approach. *IntelliSys*, 2021. arXiv:2008.06979.

[17] G. M. Campedelli, G. Daniele e M. Le Moglie. Mafia, Politics and Machine Predictions. CEPR Discussion Paper 19322, 2024.

[18] C. Elkan e K. Noto. Learning Classifiers from Only Positive and Unlabeled Data. *KDD*, p. 213–220, 2008.

[19] N. M. Mohamad Noor e S. H. Ab Hamid. Comparison of Triangular and Trapezoidal Membership Functions for Improving Decision Making in Crime Prevention. *Frontiers in Artificial Intelligence and Applications*, 261, 2014. DOI 10.3233/978-1-61499-399-5-69.

[20] K. Lum e W. Isaac. To Predict and Serve? *Significance*, 13(5):14–19, 2016.

A Uso de assistente de IA

Usamos um assistente de IA (Claude, via Claude Code) para gerar e revisar parte do código e do texto. Todo o código foi lido, executado e conferido pela equipe; os números do relatório vêm da execução dos notebooks com `seed = 42`. Principais pedidos feitos ao assistente:

1. "Monte a base municipal do VDE 2020–2024 para os estados da Amazônia Legal e junte com a população do IBGE pelo código do município."
2. "Extraia do PDF do Cartografias 2025 os quadros de facções por município de cada estado."
3. "O município da Amazônia Legal tem presença de facção criminosa (2024), dado o seu porte e o padrão de violência registrado entre 2021 e 2023? E o modelo antecipa quais municípios passaram a ter facção em 2025? Implemente as 6 etapas do enunciado."
4. "Implemente do zero o ID3, o gradiente descendente, a logística, o Naive Bayes, o EM e a inferência por enumeração, e compare com scikit-learn e pgmpy."
5. "Torne a validação mais rigorosa: probabilidades fora da dobra, tercis calculados no treino e validação deixando um estado de fora."
6. "Teste outras variáveis do IBGE e de bases abertas do governo (fronteira por município, garimpo e desmatamento, IBAMA), sem passar do limite de 6 atributos."
7. "Procure artigos científicos que embasem o trabalho." (Títulos, autores e trechos citados foram conferidos nos PDFs.)
8. "Prepare o trabalho para entrega conforme o enunciado (relatório LaTeX de 6–8 páginas, README e notebooks)."

B Reprodução

`pip install -r requirements.txt`; `python utils.py`; executar `etapa1.ipynb` a `etapa6.ipynb` em ordem (a Etapa 5 grava `dados/probabilidades_bayesianas.csv`, lido pela Etapa 6). Repositório: `https://github.com/RomarioAndrade/seguranca-publica-ml-fuzzy`.